บทที่ 7

ระบบปฏิบัติการ

(Operating Systems)

วัตถุประสงค์

หลังจากเรียนจบบทที่ 7 แล้ว นักศึกษาต้องสามารถ:

- เข้าใจและอธิบายวัตถุประสงค์และหน้าที่ของระบบปฏิบัติการได้
- เข้าใจและอธิบายองค์ประกอบของระบบปฏิบัติการได้
- เข้าใจและอธิบายมโนทัศน์ของหน่วยความจำเสมือน
- เข้าใจและอธิบายมโนทัศน์ของ deadlock และ starvation
- อธิบายคุณสมบัติของระบบปฏิบัติการที่ใช้กันอย่างแพร่หลายเช่น Windows 2000, UNIX, and Linux

บทนำ

คอมพิวเตอร์เป็นระบบที่เกิดขึ้นจากองค์ประกอบ 2 ส่วนคือ ฮาร์ดแวร์กับซอฟท์แวร์ ฮาร์ดแวร์เป็นอุปกรณ์หรือเป็นตัวเครื่องที่จับต้องได้ ส่วนซอฟท์แวร์เป็นเซตของโปรแกรมที่ทำให้ฮาร์ดแวร์สามารถทำงานได้

ซอฟท์แวร์คอมพิวเตอร์แบ่งออกเป็น 2 ประเภทคือ

- ระบบปฏิบัติการ (operating system) ทำหน้าที่ช่วยให้ผู้ใช้สามารถเข้าถึงและใช้ฮาร์ดแวร์ได้อย่างสะดวก
- ซอฟท์แวร์ประยุกต์ (application software) ทำหน้าที่ใช้ฮาร์ดแวร์ให้แก้ปัญหาตามที่ผู้ใช้ต้องการ

รูปที่ 7-1

ระบบคอมพิวเตอร์

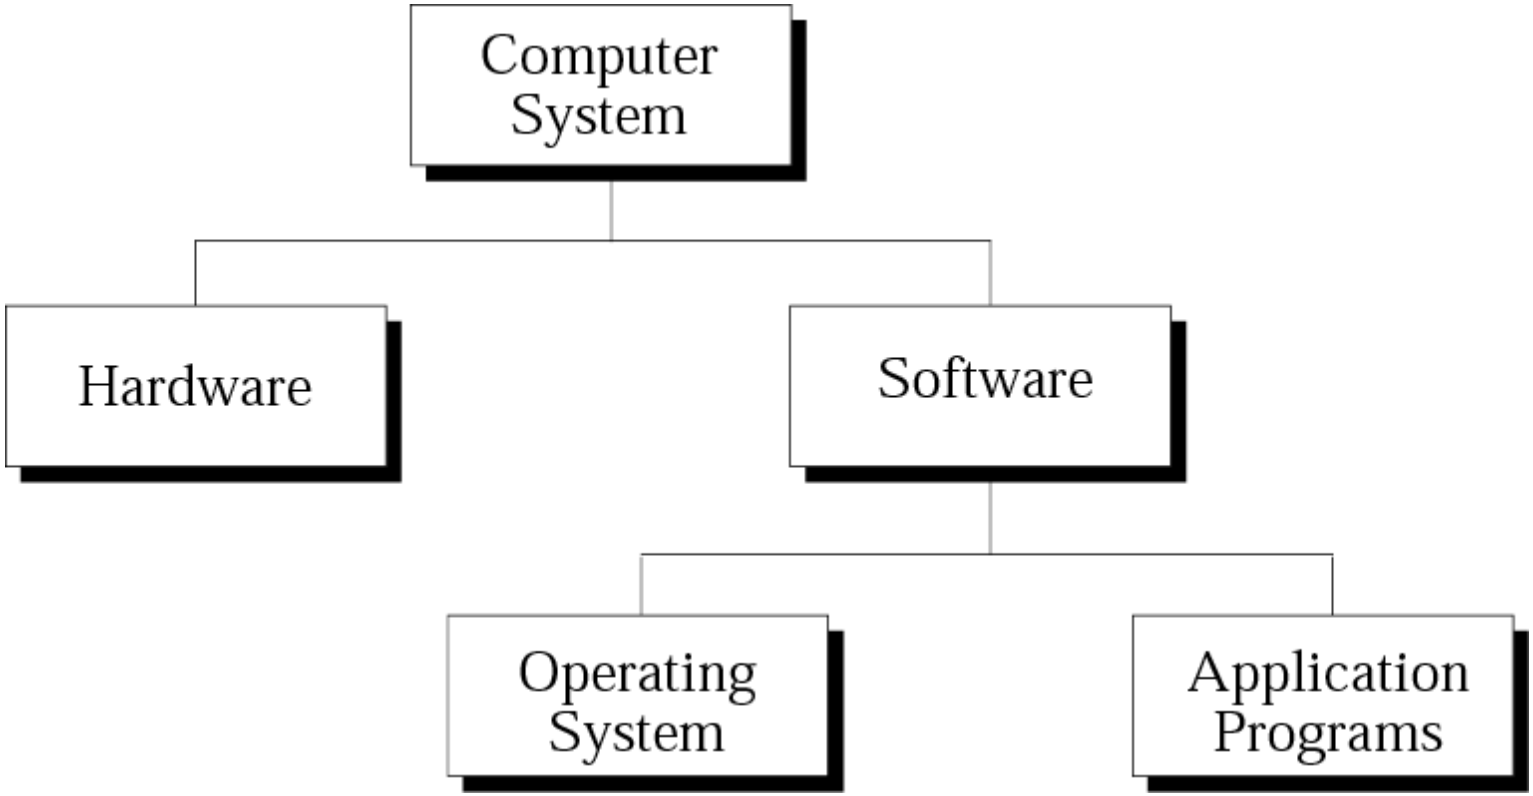

7.1

ระบบปฏิบัติการคืออะไร?

ระบบปฏิบัติการ (OS) เป็นซอฟท์แวร์ที่ซับซ้อน ยากแก่การให้คำจำกัดความที่กะทัดรัด แต่พอจะให้คำนิยามกว้างๆดังนี้

- OS เป็นซอฟท์แวร์ที่เชื่อมต่อ (interface) ระหว่างฮาร์ดแวร์กับผู้ใช้ (user) ซึ่งอาจเป็นโปรแกรมหรือคนก็ได้
- OS เป็นซอฟท์แวร์ (เซตของโปรแกรม) ที่ช่วยทำให้การ execute โปรแกรมอื่นเป็นไปได้โดยไม่ยาก
- OS ทำหน้าที่คล้ายกับผู้จัดการที่คอยให้คำแนะนำและควบคุมการทำงานของแต่ละส่วนของระบบคอมพิวเตอร์ ในฐานะที่เป็นผู้จัดการ OS จะคอยตรวจสอบทั้งฮาร์ดแวร์และซอฟท์แวร์เพื่อให้ทำงานให้มีประสิทธิภาพสูงสุด และเมื่อมีการขัดแย้งกันในการใช้ทรัพยากรในการทำงาน OS ก็จะเป็นตัวกลางในการแก้ปัญหา

An operating system is an interface between the hardware of a computer and the user (program or human) that facilitates the execution of the other programs and the access to hardware and software resources.

วัตถุประสงค์ของการออกแบบระบบปฏิบัติการ

1. ต้องทำให้การใช้ฮาร์ดแวร์มีประสิทธิภาพสูงสุด

2. ต้องทำให้การใช้ทรัพยากรคอมพิวเตอร์เป็นไปด้วยความสะดวก

7.2

วิวัฒนาการของระบบปฏิบัติการ

ระบบปฏิบัติการ มีประวัติและวิวัฒนาการเป็นระยะเวลายาวนาน แบ่งเป็นช่วงๆ สรุปได้ดังนี้

1. ระบบปฏิบัติการแบบแบทช์ (batch operating systems) ออกแบบสร้างขึ้นในช่วงปี พ.ศ. 2493 เพื่อควบคุมการทำงานของคอมพิวเตอร์ประเภทเมนเฟรม ณ เวลานั้น คอมพิวเตอร์เป็นเครื่องจักรขนาดใหญ่ที่ใช้บัตรเจาะรู (punched cards) เป็นสื่อนำเข้า (inputs) ใช้เครื่องพิมพ์ความเร็วสูง (line printers) เป็นสื่อแสดงผล (outputs) และใช้เทปแม่เหล็กเป็นหน่วยความจำสำรอง

แต่ละโปรแกรมที่จะทำการ execute จะเรียกว่า job นักเขียนโปรแกรมที่ต้องการ execute โปรแกรมจะต้องนำบัตรเจาะรูที่เป็นโปรแกรมและข้อมูลไปที่ห้องคอมพิวเตอร์ นักเขียนโปรแกรมไม่

สามารถควบคุมหรือติดต่อกับคอมพิวเตอร์ได้ ผู้ที่นำโปรแกรมและข้อมูลเข้าไปให้เครื่องคอมพิวเตอร์ทำการประมวลผลคือ operator ถ้าโปรแกรมไม่มีความผิดพลาด เครื่องจะทำการพิมพ์ผลออกทางเครื่องพิมพ์เพื่อส่งให้นักเขียนโปรแกรม ถ้ามีข้อผิดพลาดเครื่องก็จะพิมพ์รายการที่ผิดพลาดออกมาเพื่อนักเขียนโปรแกรมจะได้แก้ไข

ระบบปฏิบัติการในยุคนี้จะไม่ซับซ้อน เพียงทำหน้าที่ในการเปลี่ยนถ่ายทรัพยากรจากโปรแกรมหนึ่งไปสู่อีกโปรแกรมหนึ่งเท่านั้น

2. ระบบปฏิบัติการแบบใช้ทรัพยากรร่วมกัน (time-sharing operating systems) เพื่อให้การใช้ทรัพยากรคอมพิวเตอร์มีประสิทธิภาพสูงสุด ระบบการทำงานแบบหลายโปรแกรม (multiprogramming) จึงถูกคิดขึ้น แนวความคิดคือเก็บหลายๆ job ไว้ในหน่วยความจำหลักและทำการจัดสรรทรัพยากรให้กับ job ทีละ 1 job ที่ต้องการภายใต้เงื่อนไขที่ว่าทรัพยากรต้องว่างจากการใช้งาน

ตัวอย่างเช่นมี job หนึ่งกำลังใช้อุปกรณ์ I/O ทำให้ CPU ว่างและสามารถจัดให้กับ job อื่นได้ ระบบ multiprogramming นำไปสู่แนวคิดของการใช้ทรัพยากรร่วมกัน (time sharing) แต่ละ job จะถูกจัดสรรเวลาให้ใช้ทรัพยากรเดียวกันในเวลาที่ต่างกัน เนื่องจากคอมพิวเตอร์สามารถทำงานได้รวดเร็วมาก ผู้ใช้จะรู้สึกเสมือนว่าเขาเป็นผู้ใช้เพียงคนเดียว

Multiprogramming นับเป็นแนวคิดที่เพิ่มประสิทธิภาพการทำงานของคอมพิวเตอร์อย่างมาก ทำให้ต้องใช้ระบบปฏิบัติการที่มีความซับซ้อนมากขึ้นด้วย ระบบปฏิบัติการที่ว่าจะต้องสามารถจัดตารางลำดับการใช้งาน (scheduling) นั่นคือจะต้องทำการตัดสินใจว่า job ใดจะใช้ทรัพยากรใด และใช้เมื่อใด เป็นต้น ในยุคนี้ผู้ใช้สามารถติดต่อโดยตรงได้กับคอมพิวเตอร์โดยไม่ต้องผ่าน operator และในช่วงนี้มีคำใหม่ที่เกิดขึ้นคือคำว่า “process” ซึ่งหมายถึงโปรแกรมที่อยู่ในหน่วยความจำหลักและกำลังรอทรัพยากร ส่วน job หมายถึงโปรแกรมที่จะทำการประมวลผล (run)

3. ระบบปฏิบัติการส่วนบุคคล (personal operating systems) เมื่อมีการคิดค้นคอมพิวเตอร์ส่วนบุคคลขึ้น จึงมีความจำเป็นที่จะต้องใช้ระบบปฏิบัติการส่วนบุคคลสำหรับคอมพิวเตอร์ประเภทนี้ ทำให้เกิดระบบปฏิบัติการแบบใช้คนเดียวขึ้นเช่น DOS (Disk Operating Systems) เป็นต้น

4. ระบบแบบขนาน (parallel systems) ความต้องการในการประมวลผลที่รวดเร็วและมีประสิทธิภาพมากขึ้นนั้น นำไปสู่การออกแบบระบบประเภทที่เรียกว่าระบบประมวลผลแบบขนาน นั่นคือระบบที่มี CPU หลายๆตัวอยู่ในคอมพิวเตอร์เครื่องเดียวกัน แต่ละ CPU อาจทำงานกับโปรแกรมหนึ่งหรือส่วนหนึ่งของโปรแกรม หมายถึงว่างานหลายๆงานสามารถทำพร้อมกันได้ ระบบปฏิบัติการที่ทำงานแบบนี้จะมีความซับซ้อนมากกว่าระบบที่มี CPU เพียงตัวเดียว

5. ระบบแบบกระจาย (distributed systems) เครือข่ายคอมพิวเตอร์ได้ก่อให้เกิดระบบปฏิบัติการรูปแบบใหม่ แต่ก่อน job หนึ่งๆจะทำสำเร็จบนเครื่อง

คอมพิวเตอร์เพียงเครื่องเดียว แต่ภายใต้เครือข่าย job หนึ่งอาจถูกแบ่งให้คอมพิวเตอร์หลายๆเครื่องช่วยกันทำ โดยคอมพิวเตอร์แต่ละเครื่องอาจอยู่ห่างกันเป็นร้อยหรือเป็นพันกิโลเมตรก็ได้ โปรแกรมสามารถ run บางส่วนบนเครื่องหนึ่งและอีกบางส่วนบนอีกเครื่องหนึ่งได้ถ้าเครื่องคอมพิวเตอร์เหล่านั้นมีการเชื่อมโยงถึงกันด้วยเครือข่ายเช่นอินเตอร์เน็ต นอกจากนี้เราสามารถกระจายทรัพยากรได้ด้วย เช่นโปรแกรมอาจต้องการแฟ้มข้อมูลที่อยู่ในเครื่องคอมพิวเตอร์ที่ตั้งอยู่ ณ ส่วนต่างๆของโลกนี้ (เช่นโปรแกรมการจองตั๋วเครื่องบินเป็นต้น) ระบบปฏิบัติการแบบกระจายจะรวมเอาความสามารถของระบบปฏิบัติการที่กล่าวมาแล้วผนวกกับความสามารถในเรื่องของการรักษาความปลอดภัยเข้าไปด้วย

7.3

องค์ประกอบของระบบปฏิบัติการ

ในปัจจุบันระบบปฏิบัติการมีความซับซ้อนมาก จำเป็นที่จะต้องมีการบริหารจัดการทรัพยากรระบบคอมพิวเตอร์ทั้งระบบ เปรียบเหมือนองค์กรที่ต้องมีผู้จัดการหลายๆคนทำงานร่วมกัน แต่ละคนก็รับผิดชอบแต่ละฝ่ายและต้องทำงานประสานกัน ระบบปฏิบัติการสมัยใหม่จะต้องมีหน้าที่อย่างน้อย 4 หน้าที่หลักคือ

1. หน้าที่จัดการหน่วยความจำ (memory management)
2. หน้าที่จัดการกระบวนการ (process management)
3. หน้าที่จัดการอุปกรณ์ (device management)
4. หน้าที่จัดการแฟ้มข้อมูล (file management)

มีอีกองค์ประกอบหนึ่งที่ทำหน้าที่สื่อสาร ติดต่อระหว่างระบบปฏิบัติการกับสิ่งแวดล้อมภายนอกคือ user interface

รูปที่ 7-2

องค์ประกอบของระบบปฏิบัติการ

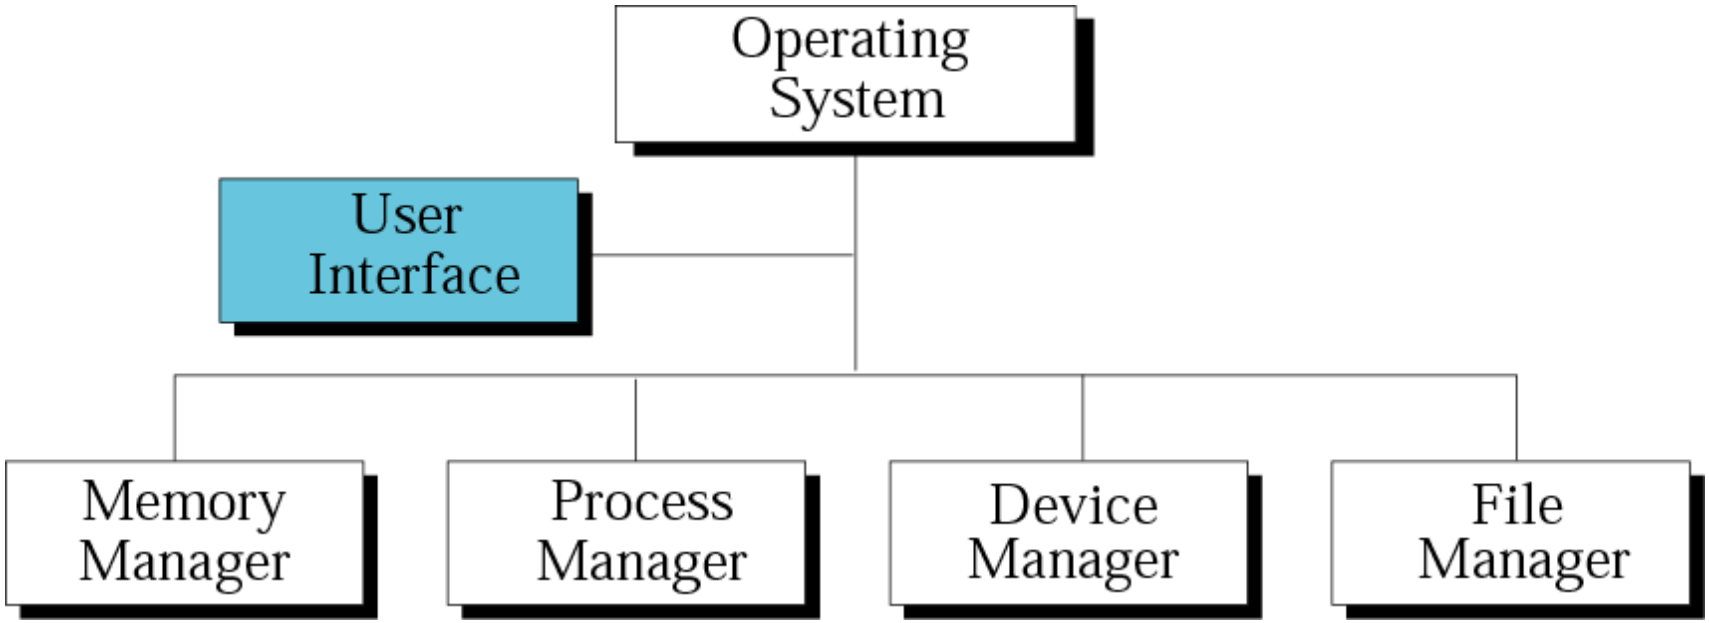

1. MEMORY MANAGEMENT

- การจัดการหน่วยความจำเป็นงานที่ระบบปฏิบัติการจะต้องจัดสรรหน่วยความจำให้กับ process ที่ต้องการใช้ แม้ว่าในปัจจุบันหน่วยความจำจะมีขนาดเพิ่มขึ้น แต่ขนาดของโปร แกรมและข้อมูลก็มีขนาดเพิ่มขึ้นตามไปด้วย การจัดสรรทรัพยากรหน่วยความจำจะต้องป้องกันปัญหาที่เรียกว่า “running out of memory” คือใช้หน่วยความจำจนหมด
- ระบบปฏิบัติการอาจแบ่งออกเป็น 2 ประเภทใหญ่ๆตามลักษณะการจัดการหน่วยความจำคือ monoprogramming และ multiprogramming

Monoprogramming

เป็นระบบปฏิบัติการที่มีใช้ในอดีต แต่ก็จะต้องทำความเข้าใจเพื่อที่จะทำให้เข้าใจ multiprogramming ที่จะกล่าวถึงต่อไปได้ดีขึ้น ในการจัดการหน่วยความจำแบบ monoprogramming นั้น หน่วยความจำเกือบทั้งหมดจะถูกจัดสรรให้กับโปรแกรมเพียงโปรแกรมเดียว ส่วนที่เหลือจะใช้เก็บตัวระบบปฏิบัติการเอง โปรแกรมทั้งโปรแกรมจะถูก load เข้าไปเก็บอยู่ในหน่วยความจำเพื่อรอการ execute เมื่อโปรแกรม run เสร็จหรือจบการทำงาน โปรแกรมใหม่ก็จะ load เข้าไปแทนที่โปรแกรมเดิม ดังรูปที่ 7.3

รูปที่ 7-3

Monoprogramming

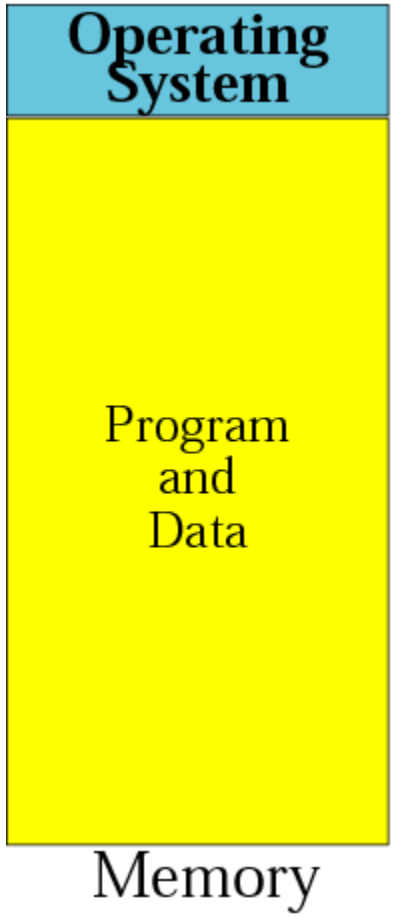

หน้าที่ของ memory manager แบบ monoprogramming

คือ (1) ทำการ load โปรแกรมเข้าไปในหน่วยความจำ (2) run โปรแกรมที่ load เข้ามา (3) แทนที่โปรแกรมที่ run เสร็จแล้วด้วยโปรแกรมต่อไป อย่างไรก็ดี การจัดการหน่วยความจำแบบนี้ก็มีปัญหาหลายประการดังนี้

1. โปรแกรมจะต้องมีขนาดที่สามารถ load เข้าไปอยู่ในหน่วยความจำได้ทั้งหมด ถ้าหน่วยความจำมีขนาดเล็กกว่าขนาดของโปรแกรม ก็จะไม่สามารถ run โปรแกรมนั้นได้
2. เมื่อมีโปรแกรมหนึ่งกำลัง run อยู่ โปรแกรมอื่นๆจะต้องรอ

ในระหว่างที่โปรแกรมหนึ่งกำลังถูก execute นั้นโดยปกติจะมีการรับข้อมูลเข้ามาจากอุปกรณ์นำเข้า และส่งผลลัพธ์ออกทางอุปกรณ์แสดงผล อุปกรณ์ I/O เหล่านี้ทำงานช้ากว่า CPU มาก ดังนั้นระหว่างที่อุปกรณ์ I/O กำลังทำงาน CPU ก็จะว่าง ไม่อาจทำงานอย่างอื่นได้เนื่องจากไม่มีโปรแกรมอื่นอยู่ในหน่วยความจำ วิธีการแบบนี้นับเป็นการใช้หน่วยความจำและ CPU ไม่สู้จะมีประสิทธิภาพเท่าที่ควรจะเป็น จึงก่อให้เกิดวิธีการใหม่ที่เรียกว่า **multiprogramming**

รูปที่ 7-4

Multiprogramming

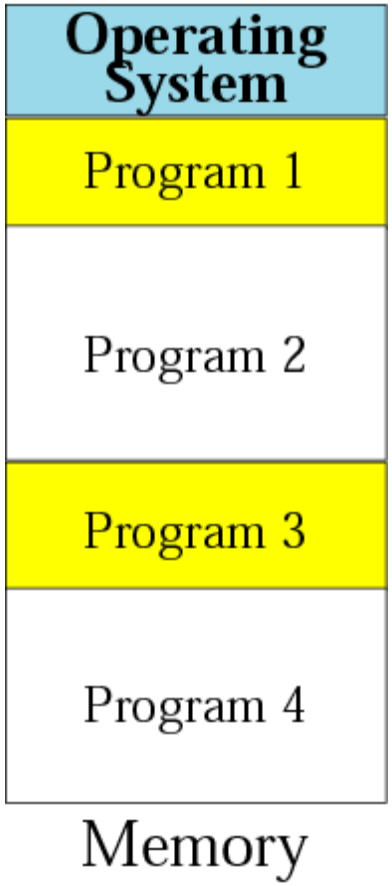

Multiprogramming

วิธีการนี้ โปรแกรมหลายๆโปรแกรมสามารถอยู่ในหน่วยความจำได้พร้อมๆกัน และสามารถ execute ได้พร้อมๆกัน (concurrent) โดย CPU จะสลับไปมาระหว่างโปรแกรม ดังรูป 7.4

ตั้งแต่ปี พ.ศ. 2503 เป็นต้นมา multiprogramming ได้มีการพัฒนาอย่างต่อเนื่อง มีการจัดรูปแบบดังรูป 7.5 ซึ่งจะเห็นว่ามี 2 รูปแบบหลักคือ

(1) Nonswapping หมายถึงโปรแกรมจะคงอยู่ในหน่วยความจำตลอดระยะเวลาที่โปรแกรมนั้นถูก execute จนกว่าจะแล้วเสร็จ

(2) Swapping หมายถึงโปรแกรมที่ถูก execute จะสลับนำไปเก็บไว้ในดิสค์กับหน่วยความจำ สลับไปมาจนกว่าจะแล้วเสร็จ

รูปที่ 7-5

ประเภทของ multiprogramming

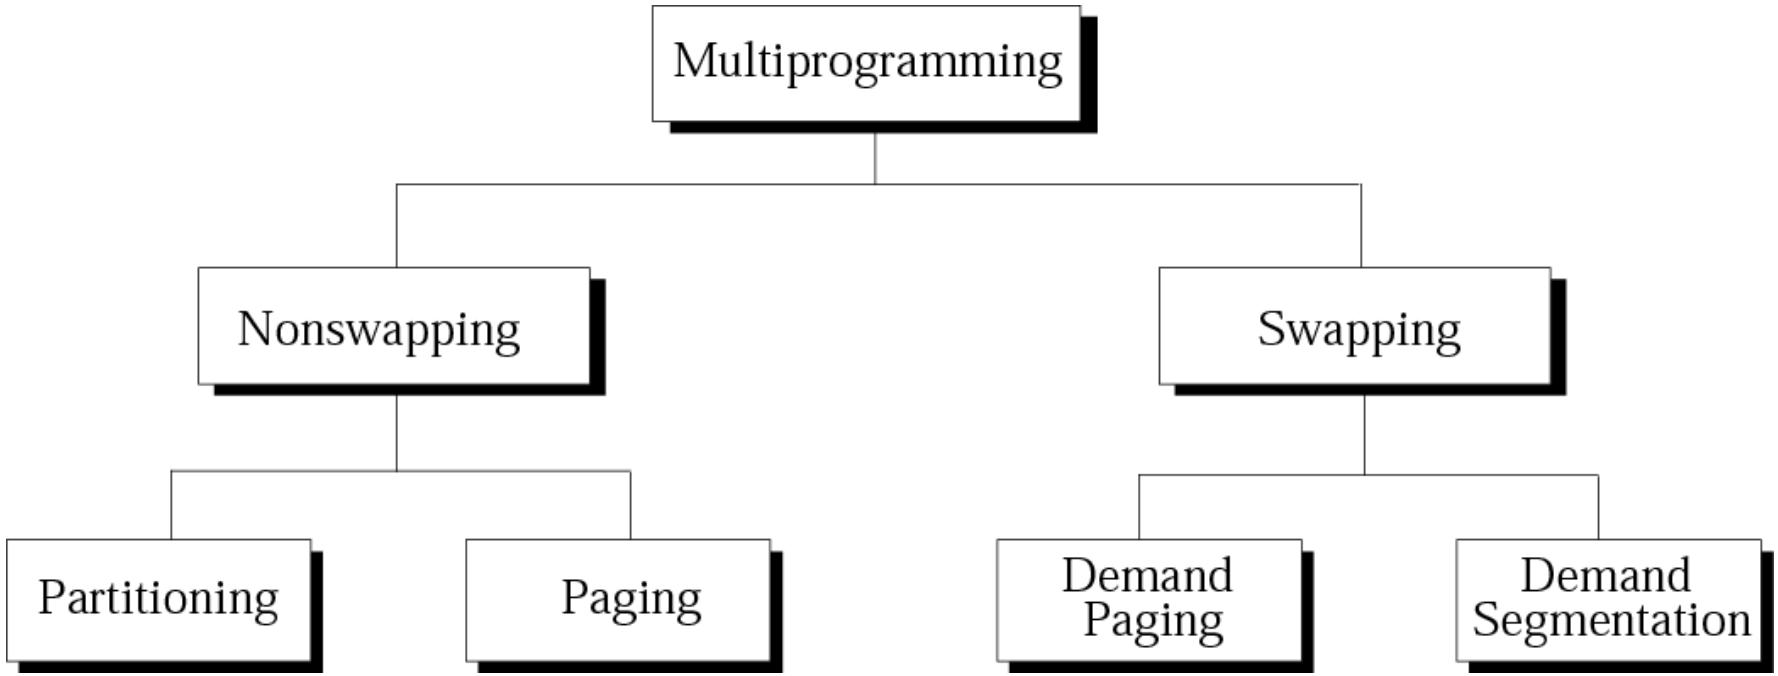

Nonswapping: มี 2 วิธีคือ

1. Partitioning: เป็นเทคนิคแรกที่ใช้ใน multiprogramming วิธีนี้หน่วยความจำจะถูกแบ่งออกเป็นหลายๆส่วนที่มีขนาดไม่เท่ากัน แต่ละส่วนเรียกว่า “พาร์ทิชั่น” (partition) แต่ละพาร์ทิชั่นจะเก็บ 1 โปรแกรม CPU จะทำงานทีละโปรแกรม การทำงานเริ่มจาก CPU ทำการ execute โปรแกรมแรกโดย execute คำสั่งต่างๆจนกระทั่งถึงคำสั่ง I/O หรือเวลาที่จัดสรรให้กับโปรแกรมนั้นหมดลง จากนั้น CPU จะเก็บที่อยู่ของคำสั่งสุดท้ายของโปรแกรมนั้นไว้ก่อนที่จะไป execute โปรแกรมในพาร์ทิชั่นอื่นต่อไป การทำงานจะวนอย่างนี้จน ทุกๆโปรแกรมถูก execute จนเสร็จทั้งหมดตามลำดับ แต่อาจมีการจัดลำดับความสำคัญของแต่ละโปรแกรมได้ ดังรูป 7.6

รูปที่ 7-6

Partitioning

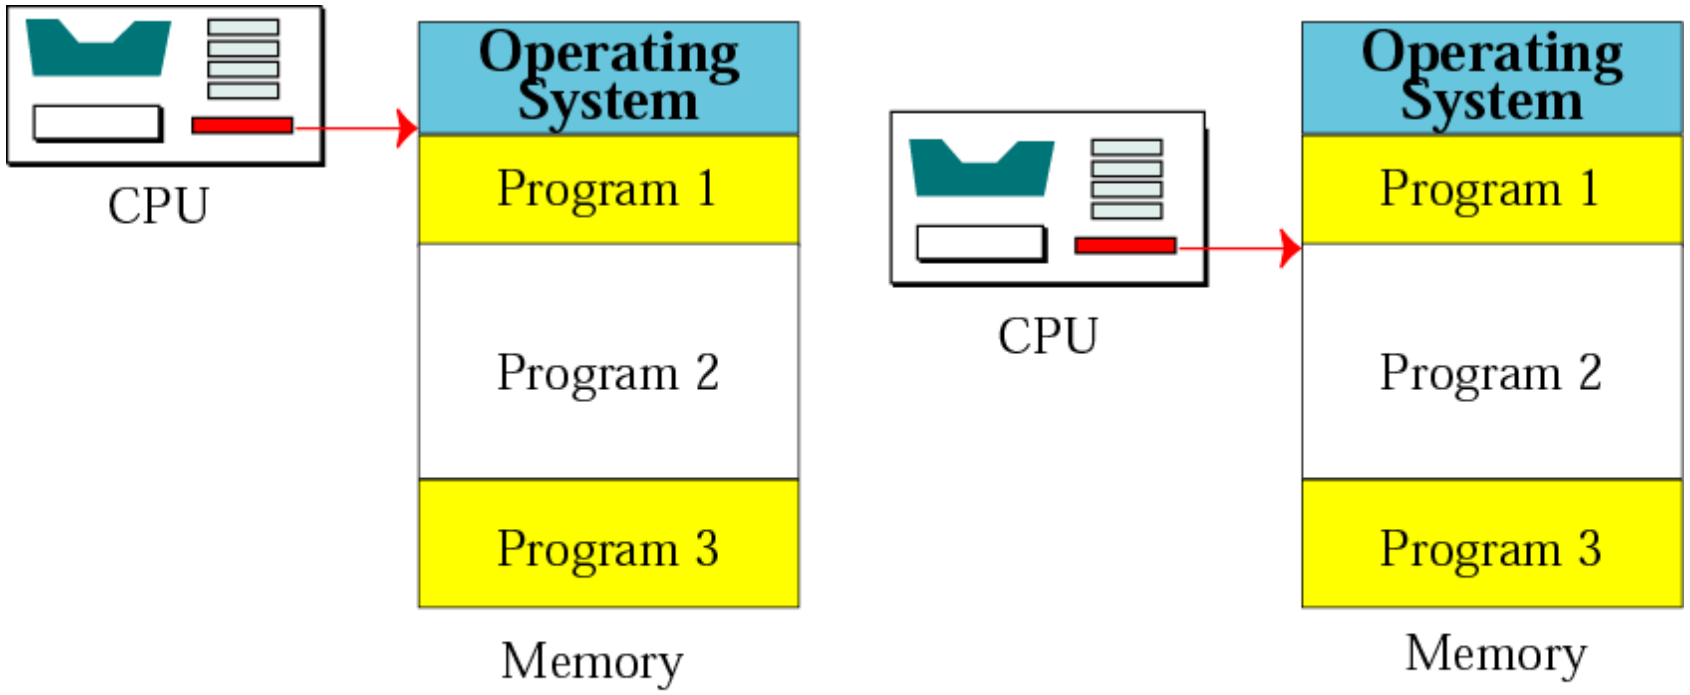

a. CPU starts executing program 1. b. CPU starts executing program 2.

ด้วยเทคนิคการแบ่งหน่วยความจำเป็นพาร์ทิชั่นนี้ แต่ละโปรแกรมจะถูกเก็บอยู่ในหน่วยความจำที่ต่อเนื่องกัน เทคนิคนี้จะช่วยให้การใช้งาน CPU มีประสิทธิภาพมากขึ้น แต่ก็ยังมีปัญหาบางประการดังนี้

• ขนาดของแต่ละพาร์ทิชั่นจะต้องถูกกำหนดล่วงหน้าโดยผู้จัดการหน่วยความจำ (memory manager) ถ้าขนาดของ พาร์ทิชั่นเล็กเกินไป บางโปรแกรมอาจจะไม่สามารถ load เข้าไปอยู่ในพาร์ทิชั่นนั้นได้ ถ้าขนาดของพาร์ทิชั่นใหญ่เกิน ไปก็อาจจะทำให้มีช่องว่างของหน่วยความจำที่ไม่ได้ใช้ประ โยชน์ เพราะขนาดของโปรแกรมไม่พอดีกับพาร์ทิชั่น

• แม้ว่าการพาร์ทิชั่นอาจจะดีและครบถ้วนสมบูรณ์ในตอนเริ่มต้น แต่อาจจะมีช่องว่างเกิดขึ้นอีกหลังจากโปรแกรมตอนต้นถูกแทนด้วยโปรแกรมต่อๆไป

• เมื่อมีช่องว่างจำนวนมาก memory manager สามารถรวมช่องว่างเหล่านั้นแล้วสร้างพาร์ทิชั่นใหม่ การทำเช่นนี้ย่อมเป็นการเสียเวลาโดยใช่เหตุ

2. **Paging**: วิธี paging ช่วยเพิ่มประสิทธิภาพของวิธี partitioning ในวิธี paging หน่วยความจำจะถูกแบ่งออกเป็นส่วนๆ แต่ละส่วนมีขนาดเท่ากัน แต่ละส่วนเรียกว่า**เฟรม (frame)** ในขณะที่โปรแกรมถูกแบ่งออกเป็นส่วนๆเช่นกัน แต่ละส่วนมีขนาดเท่ากัน เรียกแต่ละส่วนว่า **page** โดยปกติขนาดของ **frame** จะเท่ากับขนาดของ **page**

รูปที่ 7-7

Paging

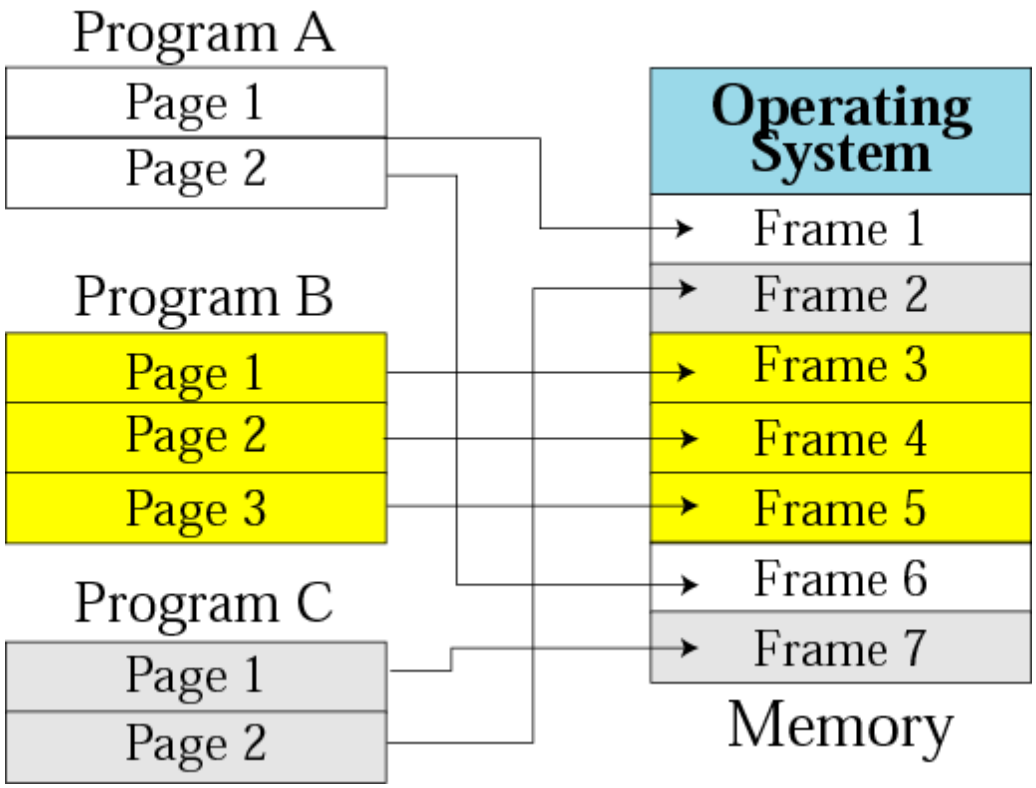

วิธี paging ทำงานโดยการ load แต่ละ page ของโปรแกรมเข้าไปเก็บใน frame ในหน่วยความจำ ถ้าโปรแกรมมี 3 page ก็จะใช้หน่วย ความจำจำนวน 3 เฟรม ด้วยวิธีการนี้ โปรแกรมไม่จำเป็นจะต้องเก็บในหน่วยความจำที่เรียงต่อเนื่องกัน

ข้อดีของวิธี paging เมื่อเปรียบเทียบกับวิธี partitioning คือ วิธี paging ช่วยเพิ่มประสิทธิภาพการจัดการหน่วยความจำระดับหนึ่ง แต่การ execute แต่ละครั้งก็ยังต้อง load ทั้งโปรแกรมเข้าไปเก็บในหน่วยความจำเช่นเดียวกัน นั่นหมายความว่าโปรแกรมที่ต้องการ 6 เฟรมในการ execute จะไม่สามารถทำได้หากในหน่วยความจำมีเฟรมที่ยังไม่ได้ใช้แค่ 4 เฟรมเหลืออยู่

3. Demand Paging: วิธี paging ไม่จำเป็นต้องให้โปรแกรมถูก load เข้าไปหน่วยความจำที่ติดต่อเนื่องกัน แต่ต้องการว่าโปรแกรมทั้งโปรแกรมต้องอยู่ในหน่วยความจำทั้งหมด วิธีการ demand paging กำจัดข้อจำกัดนี้ออกไป โดยมีข้อยืดหยุ่นกว่าคือโปรแกรมจะ load เข้าไปในหน่วยความจำเฉพาะ page ที่กำลัง execute เท่านั้น เมื่อ page ถูก execute เสร็จก็จะนำออกแล้วทำการ load เฉพาะ page ที่จะทำการ execute เป็นลำดับต่อไปเข้าไปสู่หน่วยความจำแทน กล่าวอีกอย่างหนึ่งคือหน่วยความจำสามารถเก็บ page 1 page จากหลายๆโปรแกรมในเวลาเดียวกันได้ ยิ่งไปกว่านั้น หลายๆ pages ที่ต่อเนื่องกันจากโปรแกรมเดียวกัน ไม่จำเป็นที่จะต้อง load เข้าไปอยู่ในเฟรมเดียวกัน แต่ละ page อาจ load เข้าไปเก็บในเฟรมใดๆก็ได้ที่ว่างอยู่

4. **Demand Segmentation**: วิธีการที่คล้ายๆกับวิธี paging คือวิธี segmentation ในวิธี paging โปรแกรมจะถูกแบ่งออกเป็น page ที่มีขนาดเท่าๆกัน ซึ่งแตกต่างจากวิธีที่นักเขียนโปรแกรมคิด นักเขียนโปรแกรมมองว่าโปรแกรมแบ่งออกเป็นส่วนๆ แต่ละส่วนเรียกว่าโมดูล (module) ที่ขนาดไม่จำเป็นจะต้องเท่ากัน ในวิธี segmentation โปรแกรมจะถูกแบ่งออกเป็นส่วนๆ แต่ละส่วนเรียกว่า segment ที่สอดคล้องกับแนวคิดของนักเขียนโปรแกรม segment เหล่านี้จะถูก load, execute, และ แทนที่ด้วยโมดูลอื่นจากโปรแกรมเดียวกันหรือโปรแกรมที่ต่างกันก็ได้

5. **Demand Paging และ Segmentation**: เป็นวิธีที่นำเอาวิธี paging รวมกับวิธี segmentation เพื่อเพิ่มประสิทธิภาพการบริหารจัดการหน่วยความจำให้ดียิ่งขึ้น โดยวิธีนี้ segment อาจมีขนาดใหญ่ที่พอดีกับขนาดของหน่วยความจำที่ว่างอยู่ ส่วนหน่วยความจำอาจแบ่งออกเป็นเฟรม และโมดูลแบ่งเป็น pages จากนั้น pages ของแต่ละโมดูลก็จะถูก load เข้าสู่หน่วยความจำครั้งละ 1 page แล้วทำการ execute

หน่วยความจำเสมือน : Virtual Memory

แนวคิดเกี่ยวกับ demand paging และ demand segmentation คือ ในขณะที่โปรแกรมกำลังถูก execute นั้น ส่วนหนึ่งของโปรแกรมอยู่ในหน่วยความจำหลัก อีกส่วนหนึ่งจะเก็บอยู่ในหน่วยความจำสำรอง

ตัวอย่าง: หน่วยความจำหลักขนาด 10 MB สามารถ execute โปรแกรมจำนวน 10 โปรแกรมโดยที่แต่ละโปรแกรมมีขนาด 3 MB (รวม 30 MB) ได้ วิธีการคือ ณ เวลาหนึ่ง ส่วนหนึ่งของ 10 โปรแกรมที่มีขนาด 10 MB จะอยู่ในหน่วยความจำหลัก ส่วนโปรแกรมอีก 20 MB จะเก็บอยู่ในหน่วยความจำสำรองบนดิสค์

ในสภาวะเช่นนี้ หน่วยความจำจริงๆที่มีคือ 10 MB แต่**หน่วยความจำเสมือน**มีขนาด 30 MB ในปัจจุบัน หน่วยความจำเสมือนซึ่งต้องใช้วิธี demand paging, demand segmentation หรือทั้งสองอย่าง มีการใช้งานอย่างแพร่หลายในระบบปฏิบัติการทั่วไป รูปที่ 7.8 แสดงให้เห็นแนวคิดนี้

รูปที่ 7-8

Virtual memory

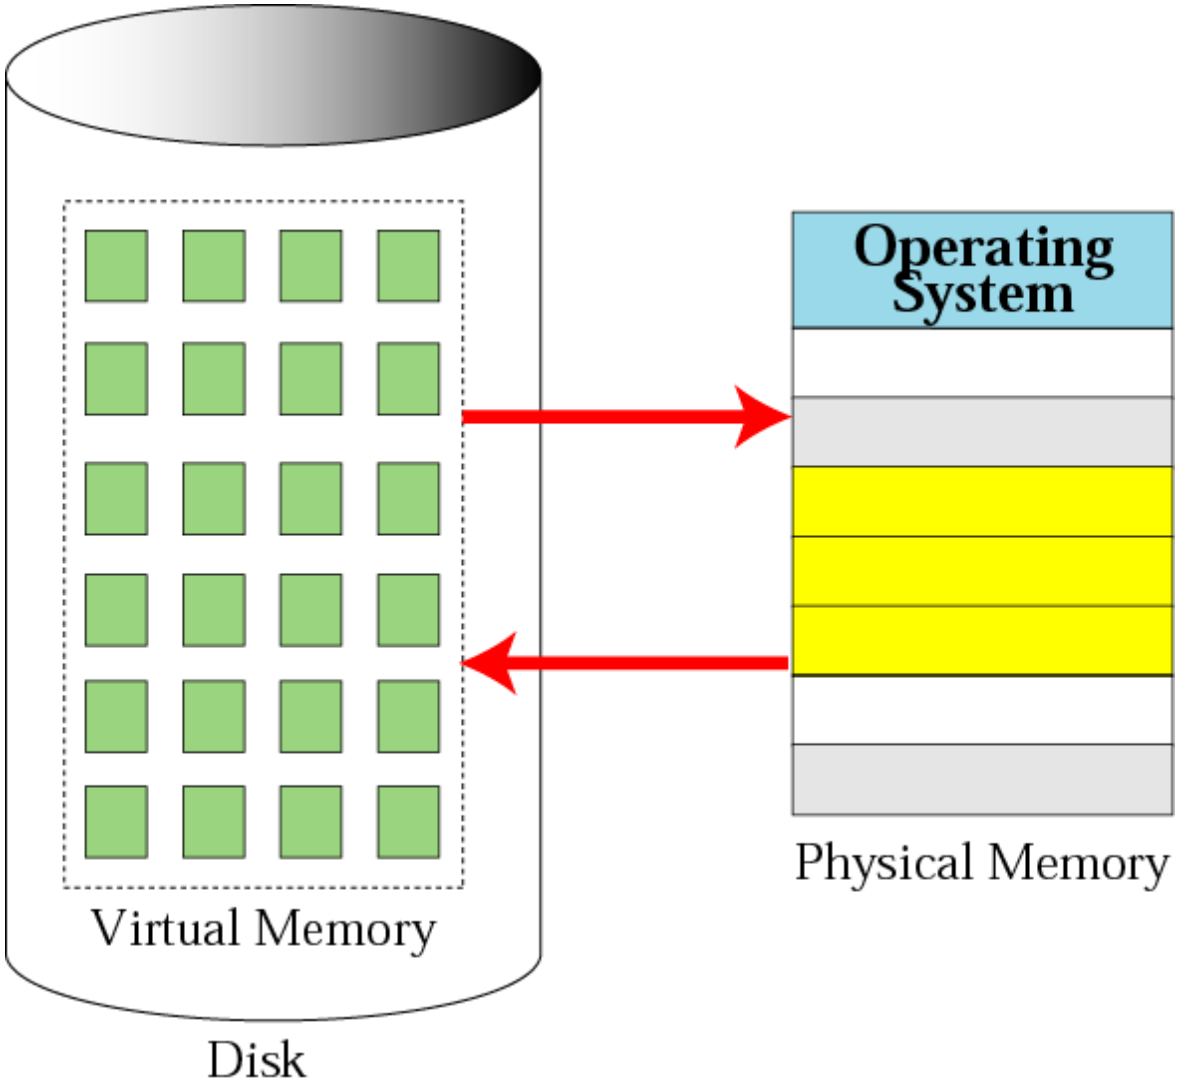

2. PROCESS MANAGEMENT

ระบบปฏิบัติการยุคใหม่ คำศัพท์ 3 คำที่ใช้โดยหมายถึงกลุ่มของคำสั่ง คือ: program, job, และ process แต่คำเหล่านี้ก็จะมีความหมายที่กว้างและแตกต่างกันไปตามระบบปฏิบัติการที่ใช้ สำหรับในชั้นนี้จะกำหนดนิยามเพื่อความเข้าใจที่ตรงกันดังต่อไปนี้

- program: หมายถึงชุดของคำสั่งที่ยังไม่มีการกระทำใดๆ (nonactive) ที่เขียนโดยนักเขียนโปรแกรมซึ่งเก็บอยู่ในดิสค์ (หรือเทป) โปรแกรมในโอกาสต่อไปอาจเป็น job หรือไม่ก็ได้
- Job: โปรแกรมจะเปลี่ยนสภาพเป็น job ทันทีที่มันถูกเลือกไป execute จนกว่าจะสำเร็จแล้วจึงเปลี่ยนสภาพกลับมาเป็นโปรแกรมอีกครั้งหนึ่ง ในช่วงเวลาดังกล่าว job อาจถูก execute หรือไม่ก็ได้ มันอาจถูกเก็บอยู่ในดิสค์เพื่อรอเวลาที่จะ load เข้าสู่หน่วยความจำหลัก หรืออาจจะรองอยู่ในหน่วย

ความจำหลักเพื่อรอการ execute จาก CPU หรืออาจจะอยู่ในดิสค์หรืออยู่ในหน่วยความจำหลักเพื่อรอเหตุการณ์ I/O หรืออาจจะอยู่ในหน่วยความจำหลักในขณะที่มันถูก execute โดย CPU คำว่าโปรแกรมจะหมายถึงทุกกรณีที่กล่าวมา เมื่อ job ถูก execute สำเร็จ (จบปกติหรือไม่ปกติก็ได้) มันจะเปลี่ยนสภาพมาเป็นโปรแกรมที่เก็บอยู่ในดิสค์ ระบบปฏิบัติการจะไม่สามารถควบคุมดูแลโปรแกรม ณ ตอนนี้ได้

ข้อสังเกต: ขอให้สังเกตว่าทุกๆ job เป็นโปรแกรม แต่อาจมีบางโปรแกรมที่ไม่ใช่ job

- **Process**: คือโปรแกรมที่อยู่ในระหว่างการ execute แต่ยังไม่เสร็จ กล่าวอีกอย่างคือ process เป็น job ทีอยู่ในหน่วยความจำหลัก มันจะถูกเลือกในระหว่าง job ที่กำลังรอคอยการ execute แล้วถูก load เข้าไปในหน่วยความจำหลัก process อาจถูก execute ทันทีหรืออาจต้องรอ CPU เมื่อถูก load

เข้าสู่หน่วยความจำหลัก เมื่อไรก็ตามที่ job อยู่ในหน่วยความจำหลัก เราจะเรียกว่า process ขอให้สังเกตว่าทุกๆ process จะเป็น job แต่บาง job ที่ไม่ได้เป็น process

2.1 แผนภาพสถานะ (State Diagram): ความสัมพันธ์ระหว่าง program, job, และ process จะมีความชัดเจนมากขึ้นถ้าเราพิจาณาว่า program เปลี่ยนไปเป็น job และ job เปลี่ยนไปเป็น process ได้อย่างไร ความสัมพันธ์นี้สามารถแสดงให้เห็นได้โดยใช้แผนภาพสถานะซึ่งจะบ่งบอกถึงสถานะของแต่ละส่วน รูปที่ 7.9 แสดงให้เห็นถึงความสัมพันธ์นี้

จากรูปจะเห็นว่า program เปลี่ยนไปเป็น job โดยระบบปฏิบัติการและนำไปสู่สถานะ 'hold' มันจะคงอยู่ในสถานะนี้จนกระทั่งถูก load เข้าไปสู่หน่วยความจำหลักเมื่อมีหน่วยความจำหลักเหลือเพียงพอที่จะ load โปรแกรมเพียงบางส่วนหรือทั้งหมด job ก็จะเปลี่ยนไปสู่สถานะ 'ready'

และเรียกว่า ‘process’ มันจะอยู่ในหน่วยความจำหลักและอยู่ในสถานะนี้จนกว่า CPU จะว่างและทำการ execute สถานะจะเปลี่ยนไปเป็น ‘running’ ในขณะที่อยู่ในสถานะ ‘running’ นั้น 3 สถานการณ์ต่อไปนี้อาจเกิดขึ้นได้

- process ถูก execute จนกระทั่งต้องการ I/O หรือ
- process ถูก execute จนหมดเวลาที่กำหนดไว้ให้ หรือ
- process ถูก execute จนจบการทำงาน

ในกรณีแรก process จะเปลี่ยนไปสู่สถานะ ‘waiting’ และคอยจนกระทั่งได้รับการจัดสรร I/O ในกรณีที่สอง process จะเปลี่ยนไปสู่สถานะ ‘ready’ ในกรณีที่สาม process จะเปลี่ยนไปสู่สถานะ ‘terminated’ และหมดสภาพการที่จะเป็น process อีกต่อไป การเปลี่ยนสถานะของ process ระหว่าง running, waiting, และ ready อาจเกิดขึ้นหลายๆครั้งก่อนที่จะไปจบลงที่สถานะ ‘terminated’ ในกรณีที่เป็นหน่วยความจำเสมือน จะซับซ้อนกว่านี้

รูปที่ 7-9

State diagram with the boundaries between a program, a job, and a process

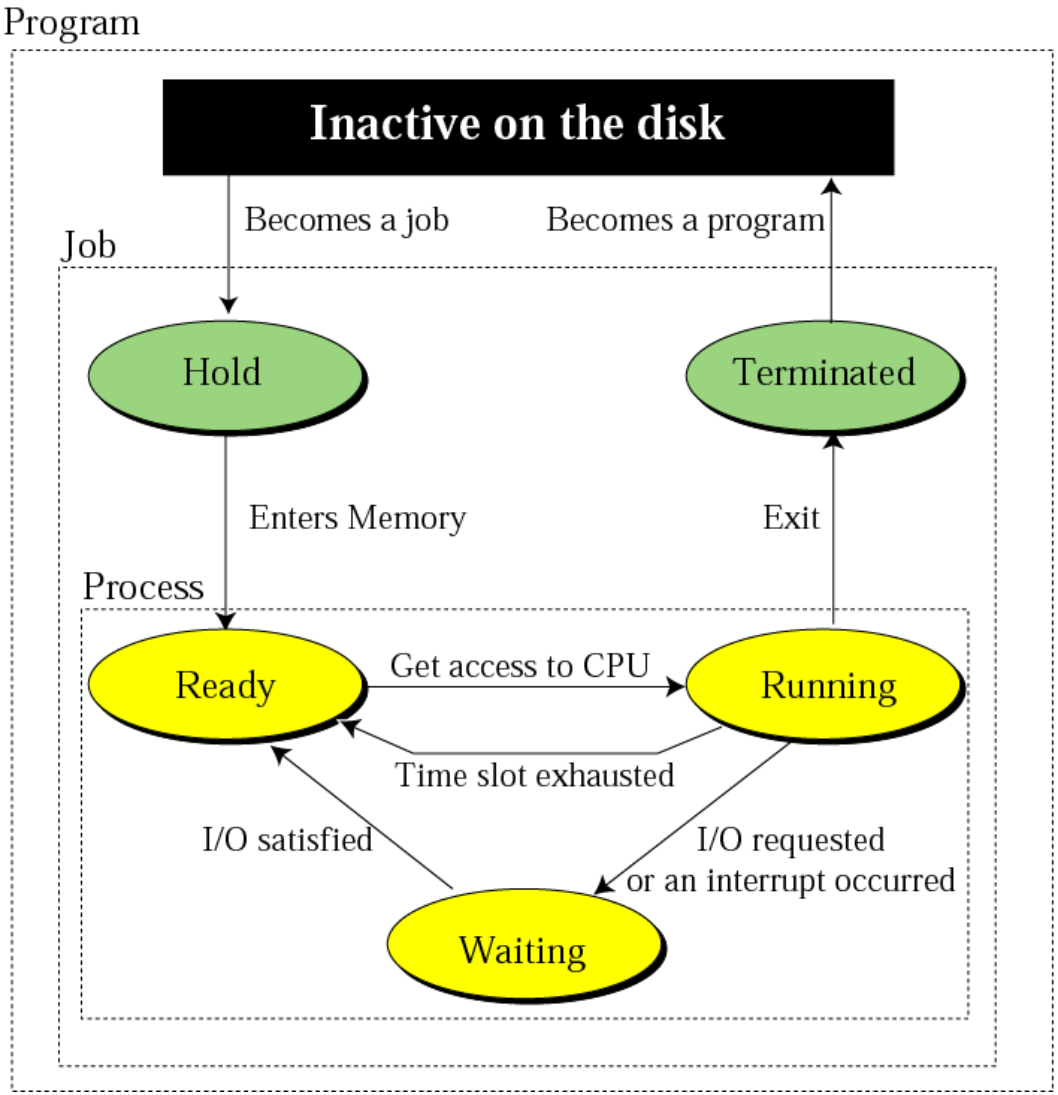

2.2 Schedulers: การที่จะเปลี่ยน job หรือ process จากสถานะหนึ่งไปเป็นอีกสถานะหนึ่งนั้น process manager จะใช้การจัดตารางเวลา 2 ลักษณะคือ job scheduler และ process scheduler

2.2.1 Job Scheduler: ทำการเปลี่ยนสถานะของ job จากสถานะ 'hold' ไปเป็นสถานะ 'ready' หรือจาก 'running' ไปเป็น 'terminated' หรือกล่าวอีกอย่างหนึ่งคือ job scheduler ทำหน้าที่สร้าง process จาก job และทำการ terminate process รูปที่ 7.10 แสดงให้เห็นการทำงานของ job scheduler ตามรูปแบบของแผนภาพสถานะ

2.2.2 Process Scheduler: ทำหน้าที่เปลี่ยน process จากสถานะหนึ่งไปเป็นอีกสถานะหนึ่งคือ (1) เปลี่ยน process จากสถานะ 'running' ไปสู่สถานะ 'waiting' เมื่อ process รอคอยเหตุการณ์บางอย่างให้เกิดขึ้น (2) เปลี่ยน process จากสถานะ 'running' ไปเป็นสถานะ 'ready' ถ้าเวลา

ที่กำหนดให้หมดลง (3) เปลี่ยน process จากสถานะ ‘waiting’ ไปสู่สถานะ ‘ready’ เมื่อมีเหตุการณ์ที่รอคอยเกิดขึ้น เมื่อ CPU พร้อมที่จะ run, process scheduler จะทำการเปลี่ยน process จากสถานะ ‘ready’ ไปเป็นสถานะ ‘running’ รูปที่ 7.11 แสดงการทำงานของ process scheduler ในรูปแบบที่แทนด้วยแผนภาพสถานะ

2.2.3 Scheduler ประเภทอื่นๆ: ระบบปฏิบัติการบางระบบใช้ schedulers ที่ซับซ้อนกว่าที่อธิบายมา เพื่อที่จะทำให้กระบวนการเปลี่ยนสถานะของ process มีประสิทธิภาพมากขึ้น

รูปที่ 7-10

Job scheduler

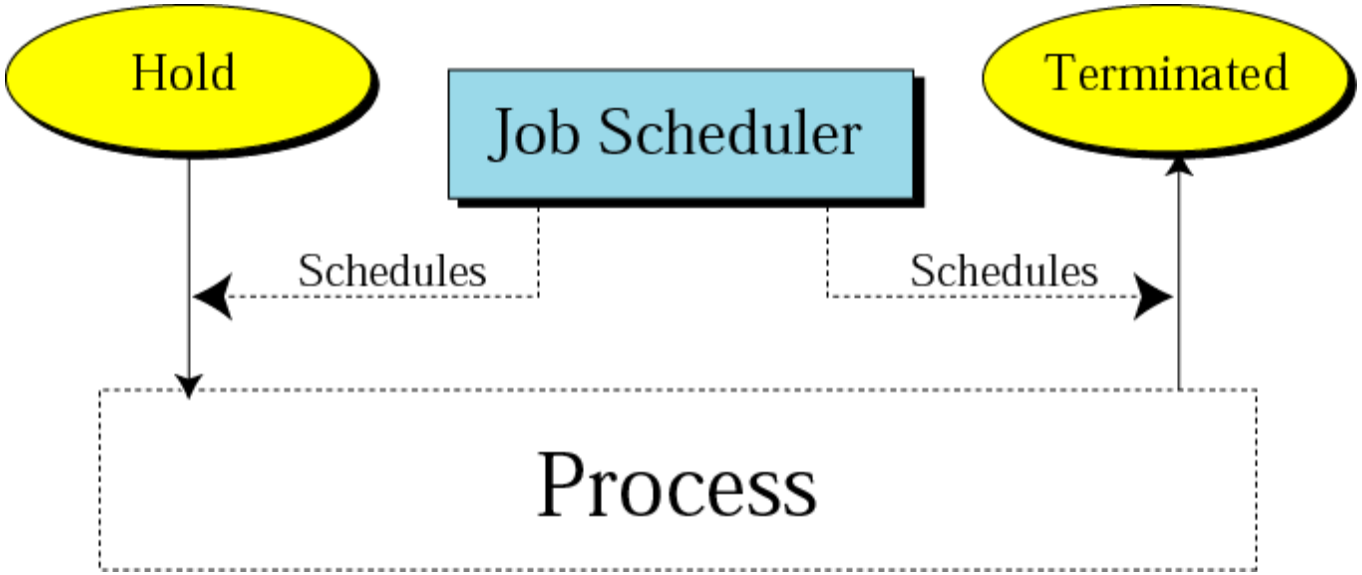

รูปที่ 7-11

Process scheduler

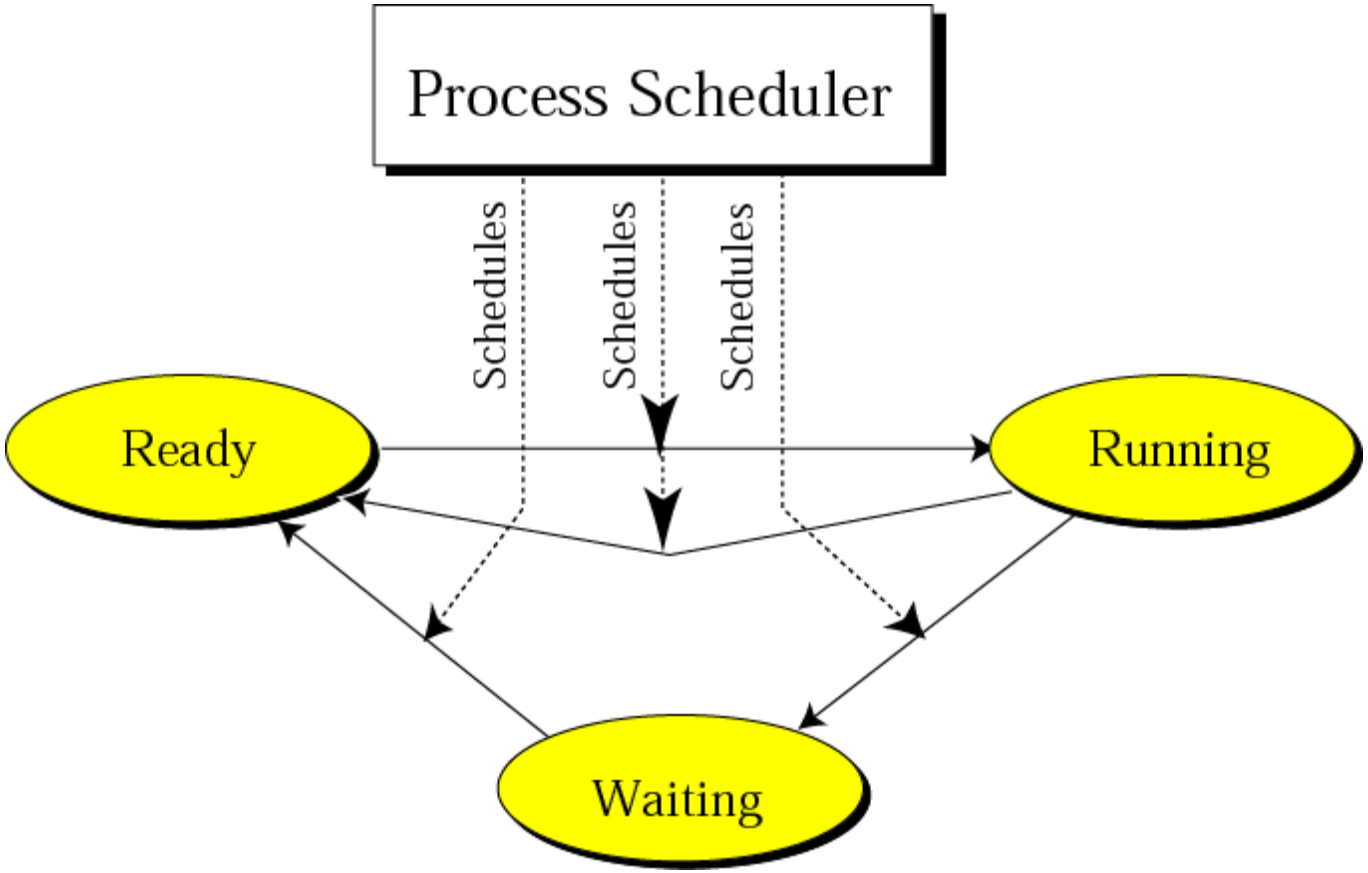

2.3 Queuing: แผนภาพสถานะแสดงให้เห็นว่า job หรือ process เปลี่ยนจากสถานะหนึ่งไปเป็นอีกสถานะหนึ่ง ความจริงที่เกิดขึ้นคือมี job และ process จำนวนมากที่แข่งขันกันเพื่อให้ได้มาซึ่งทรัพยากรที่จะต้องใช้ประมวลผล ตัวอย่างเช่น เมื่อมีหลายๆ job อยู่ในหน่วยความจำพร้อมๆกัน ยังมีอีกหลายๆ job กำลังรอหน่วยความจำที่จะว่างเพื่อที่จะ load เข้ามา หรือถ้ามี process หนึ่งกำลังใช้ CPU อยู่ ก็จะยังมี process อื่นที่รอ CPU เช่นกัน

การที่จะจัดการกับหลายๆ process และ job พร้อมๆกัน process manager ใช้ queues เป็นเครื่องมือโดยแต่ละ job และแต่ละ process จะมี job control block (JCB) หรือ process control block (PCB) ที่เก็บรายละเอียดของ job หรือ process ไว้ process manager จะเก็บ JCB หรือ PCB ไว้ใน queue ส่วน job และ process จริงจะอยู่ในหน่วยความจำหลักหรือหน่วยความจำสำรองเพราะมันใหญ่เกินไปที่จะเก็บใน queue

ดังนั้น JCB และ PCB จะแทน job และ process ที่รอทรัพยากรตามลำดับ

ในระบบปฏิบัติการโดยทั่วไปจะมีหลาย queue เช่นในรูปที่ 7.12 แสดงให้เห็นถึง job และ process กับ queue จำนวน 3 queue คือ

1) job queue: เก็บ job ที่รอหน่วยความจำหลัก
2) ready queue: เก็บ process ที่อยู่ในหน่วยความจำหลัก พร้อมที่จะ run แต่กำลังรอ CPU อยู่
3) I/O queue: เก็บ process ที่รออุปกรณ์ I/O (จริงๆแล้วมีหลาย queue เท่ากับจำนวนอุปกรณ์ I/O ที่มี)

Process manager อาจมีนโยบายหลายรูปแบบเพื่อเลือก job หรือ process ต่อไปจาก queue ซึ่งอาจเป็นมาก่อนไปก่อน (first in, first out: FIFO) สั้นที่สุดก่อน (shortest length first) หรือ มีสิทธิสูงสุด (highest priority) เป็นต้น

รูปที่ 7-12

Queues for process management

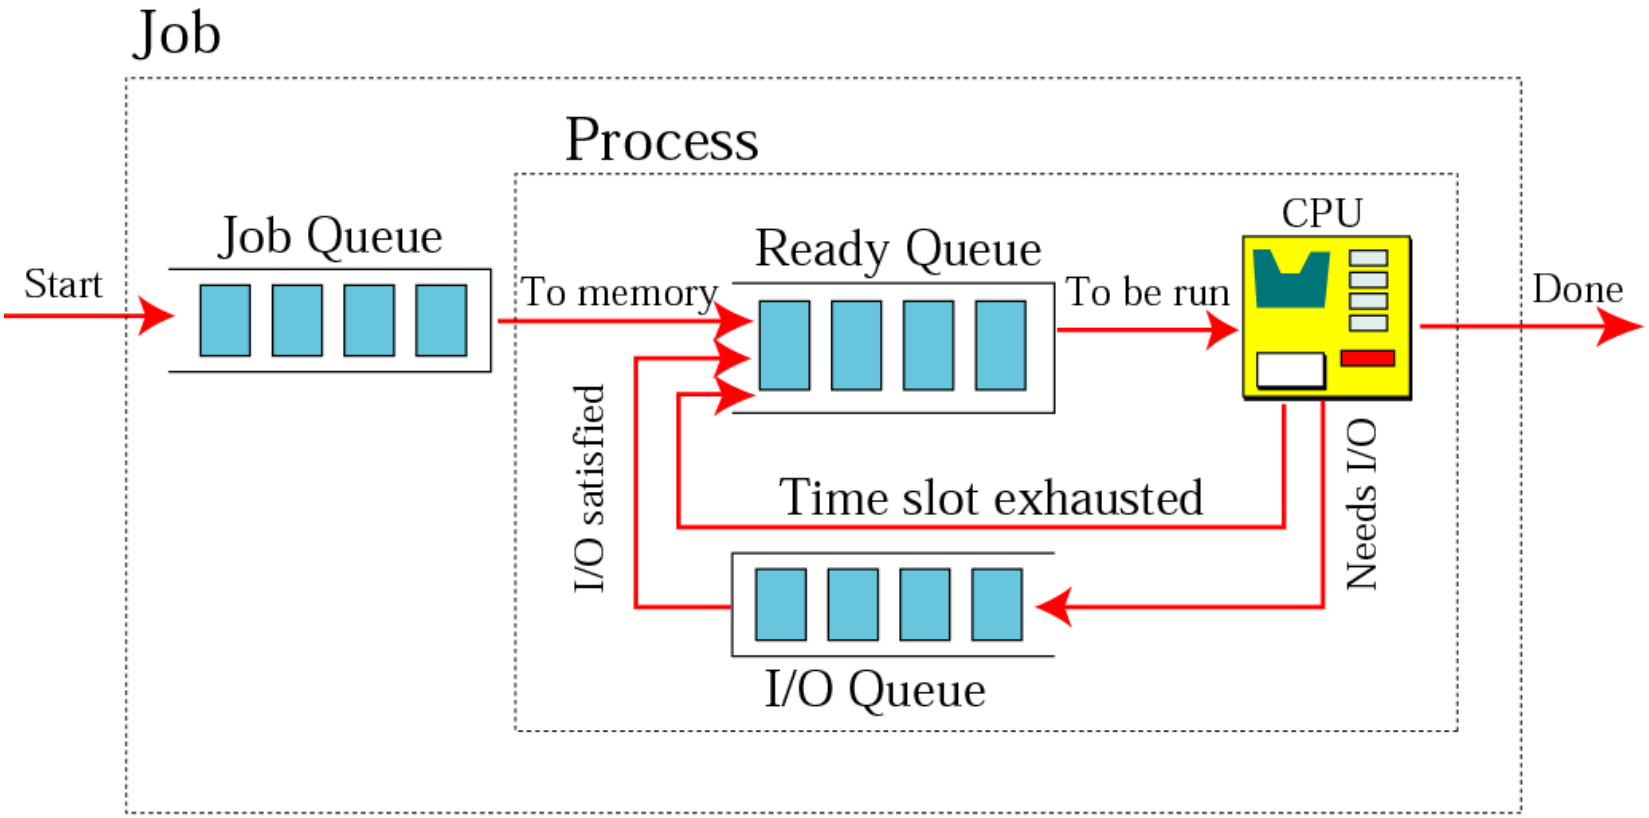

2.4 Process Synchronization: ความคิดพื้นฐานที่อยู่เบื้องหลัง process management คือการทำให้ process หลายๆ process สามารถใช้ทรัพยากรหลายๆประเภทได้พร้อมกัน เมื่อไรก็ตามที่ทรัพยากรสามารถใช้โดย process ที่มากกว่า 1 process ขึ้นไป อาจก่อให้เกิด 2 สถานการณ์ได้คือ

2.4.1 Deadlock: แทนที่จะอธิบายนิยามของคำว่า deadlock แต่จะขอยกตัวอย่างเพื่อความเข้าใจ สมมติว่ามี 2 process คือ process A กับ process B โดยที่ process A กำลังครอบครองแฟ้มข้อมูลชื่อ “File1” อยู่ และไม่สามารถปล่อยออกไปได้จนกว่าจะได้ครอบครองแฟ้มข้อมูลที่ชื่อ “File2” ส่วน process B กำลังครอบครองแฟ้มข้อมูล “File2” และไม่สามารถปล่อยออกไปได้จนกว่าจะได้ครอบครอง “File1” เนื่องจากแฟ้มข้อมูลในระบบคอมพิวเตอร์ทั่วไปจะไม่สามารถใช้ร่วมพร้อมกันได้ ถ้าไม่มีมาตรการในการปลดปล่อยแฟ้มข้อมูลที่ถือครองอยู่ ก่อนที่จะร้องขอทรัพยากรอื่น ก็จะก่อให้เกิด deadlock ได้ ดังรูป 7.13

รูปที่ 7-13

Deadlock

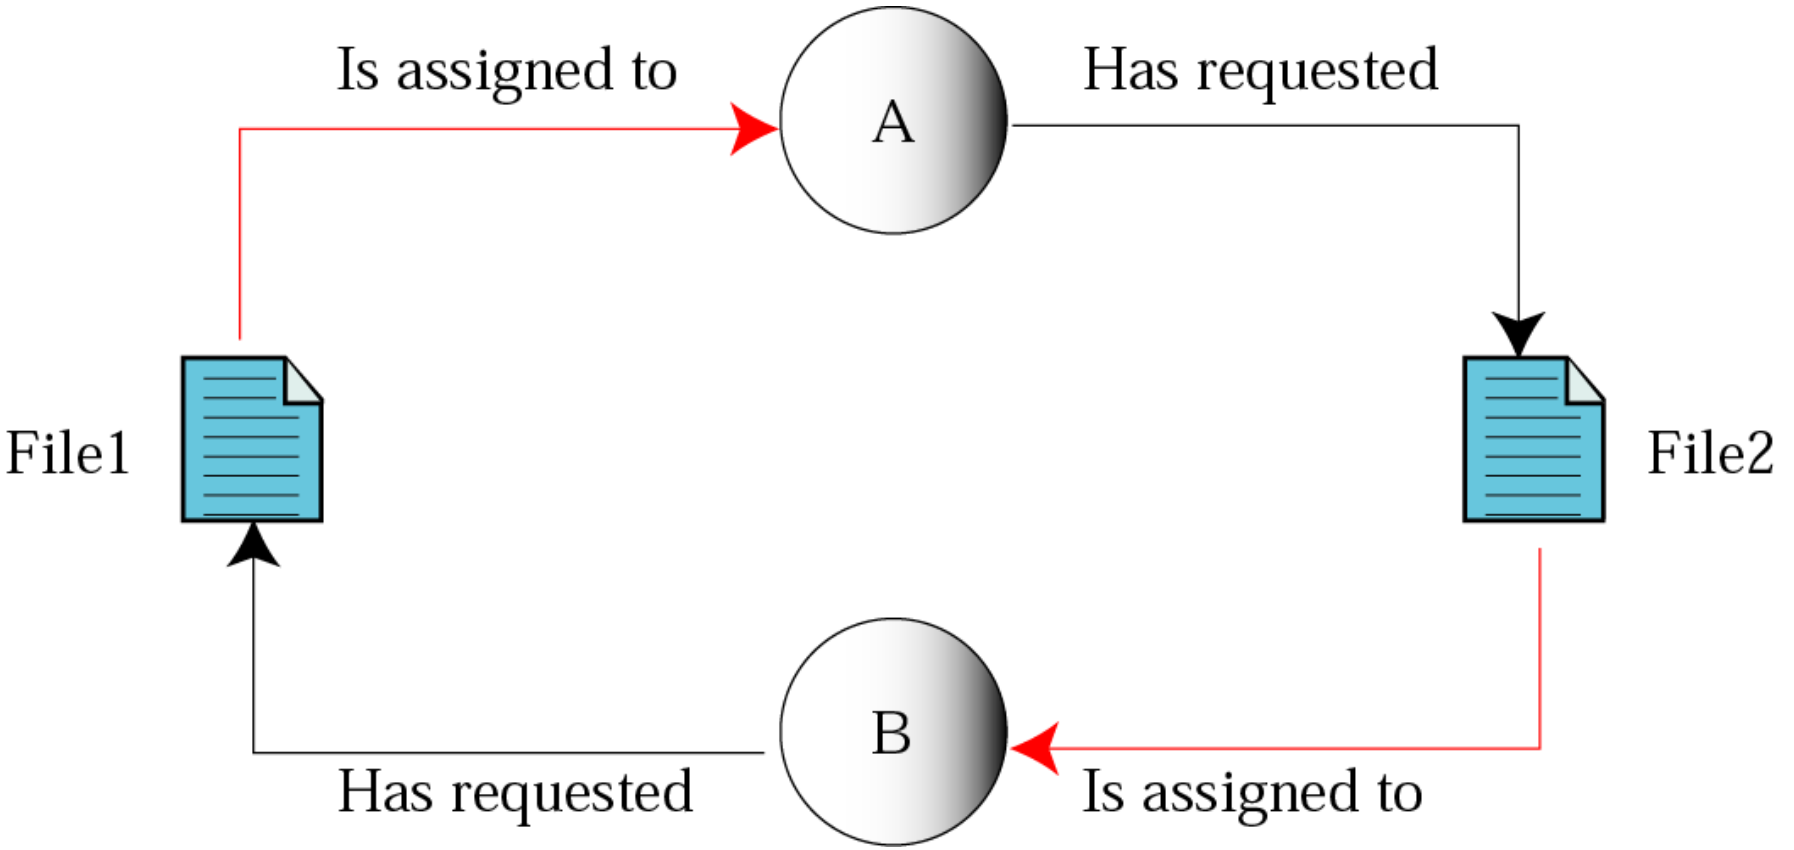

รูปที่ 7-14

Deadlock บนสะพาน

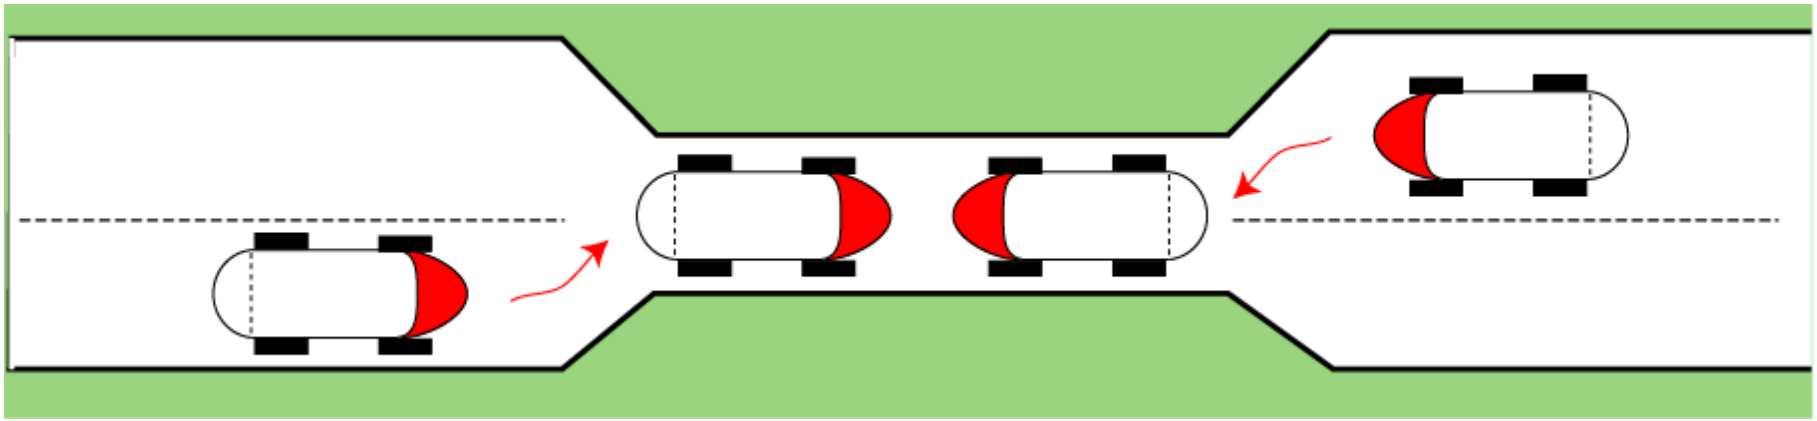

Deadlock จะเกิดขึ้นถ้าระบบปฏิบัติการยอมให้ process เริ่ม run โดยไม่ได้ตรวจสอบก่อนว่าทรัพยากรที่ต้องการนั้นว่างหรือไม่ และทำการจัดสรรให้ตามที่ต้องการทันที เพื่อป้องกันไม่ให้เกิด deadlock ในระบบ วิธีแก้อย่างหนึ่งคือไม่ยอมให้ process เริ่มทำงานจนกระทั่งทรัพยากรที่ต้องการว่างจากการใช้งาน แต่ก็ยังอาจก่อให้เกิดปัญหาอื่นอีก ส่วนทางแก้ที่สองคือกำหนดเวลาถือครองที่ process จะครอบครองทรัพยากรไว้ เมื่อครบกำหนดเวลา process ก็จะต้องปล่อยทรัพยากรที่ถือครองทันที

โดยปกติ deadlock มักจะไม่เกิดขึ้น มีเงื่อนไขที่จำเป็น 4 อย่างที่ก่อให้เกิด deadlock คือ 1) mutual exclusion คือการให้ process เดียวถือครองทรัพยากร 1 อย่าง 2) resource holding คือ process หนึ่งถือครองทรัพยากรแม้จะไม่ได้ใช้และจะปลดปล่อยต่อเมื่อได้ถือครองทรัพยากรอื่น 3) no pre-emption คือระบบปฏิบัติการไม่สามารถดึงเอาทรัพยากรกลับได้

4) circular waiting คือทุกๆ process และทรัพยากรที่เกี่ยวข้องก่อให้เกิด loop ดังรูปที่ 7.13

เงื่อนไขทั้งสี่ข้อมีความจำเป็นที่จะก่อให้เกิด deadlock ซึ่งหมายความว่าเงื่อนไขทั้งหมดต้องเกิดขึ้นก่อน ก่อนที่จะเกิด deadlock ถ้ามีเงื่อนไขใดเงื่อนไขหนึ่งหายไป deadlock จะไม่เกิด ข้อเท็จจริงนี้ทำให้เราสามารถหาวิธีป้องกัน (prevention) หรือหลีกเลี่ยง (aviodance) deadlock ได้ง่ายๆ คือป้องกันอย่าให้เงื่อนใดเงื่อนไขหนึ่งเกิดขึ้นนั่นเอง

Deadlock occurs when the operating system does not put resource restrictions on processes.

2.4.2 Starvation: เป็นเหตุการณ์ที่มีลักษณะตรงกันข้ามกับ deadlock คือ เหตุการณ์จะเกิดขึ้นเมื่อระบบปฏิบัติการมีข้อกำหนดให้ process ใช้ทรัพยากรมากเกินไป เช่นกำหนดว่า process จะต้องถือครองทรัพยากรทั้งหมดก่อนที่จะสามารถ run ได้

ตัวอย่างในรูปที่ 7.15 สมมติว่า process A ต้องการ 2 ไฟล์คือ File1 กับ File2 โดยที่ File1 กำลังถูกใช้อยู่โดย process B ส่วน File2 กำลังถูกใช้อยู่โดย process E เมื่อ run ไปได้ระยะหนึ่ง process B ทำงานเสร็จ จึงปลดปล่อย File1 ส่วน process A ยังไม่สามารถเริ่ม run ได้เพราะ File2 ยังถูกใช้งานอยู่ ในขณะเดียวกัน process C ซึ่งต้องการเฉพาะ File1 อนุญาตให้ run ได้ เมื่อผ่านไประยะหนึ่ง process E ทำงานเสร็จ จึงปลดปล่อย File2 อย่างไรก็ตาม process A ก็ยังเริ่มไม่ได้เพราะ File1 ยังถูกใช้โดย process C

รูปที่ 7-15.a

Starvation

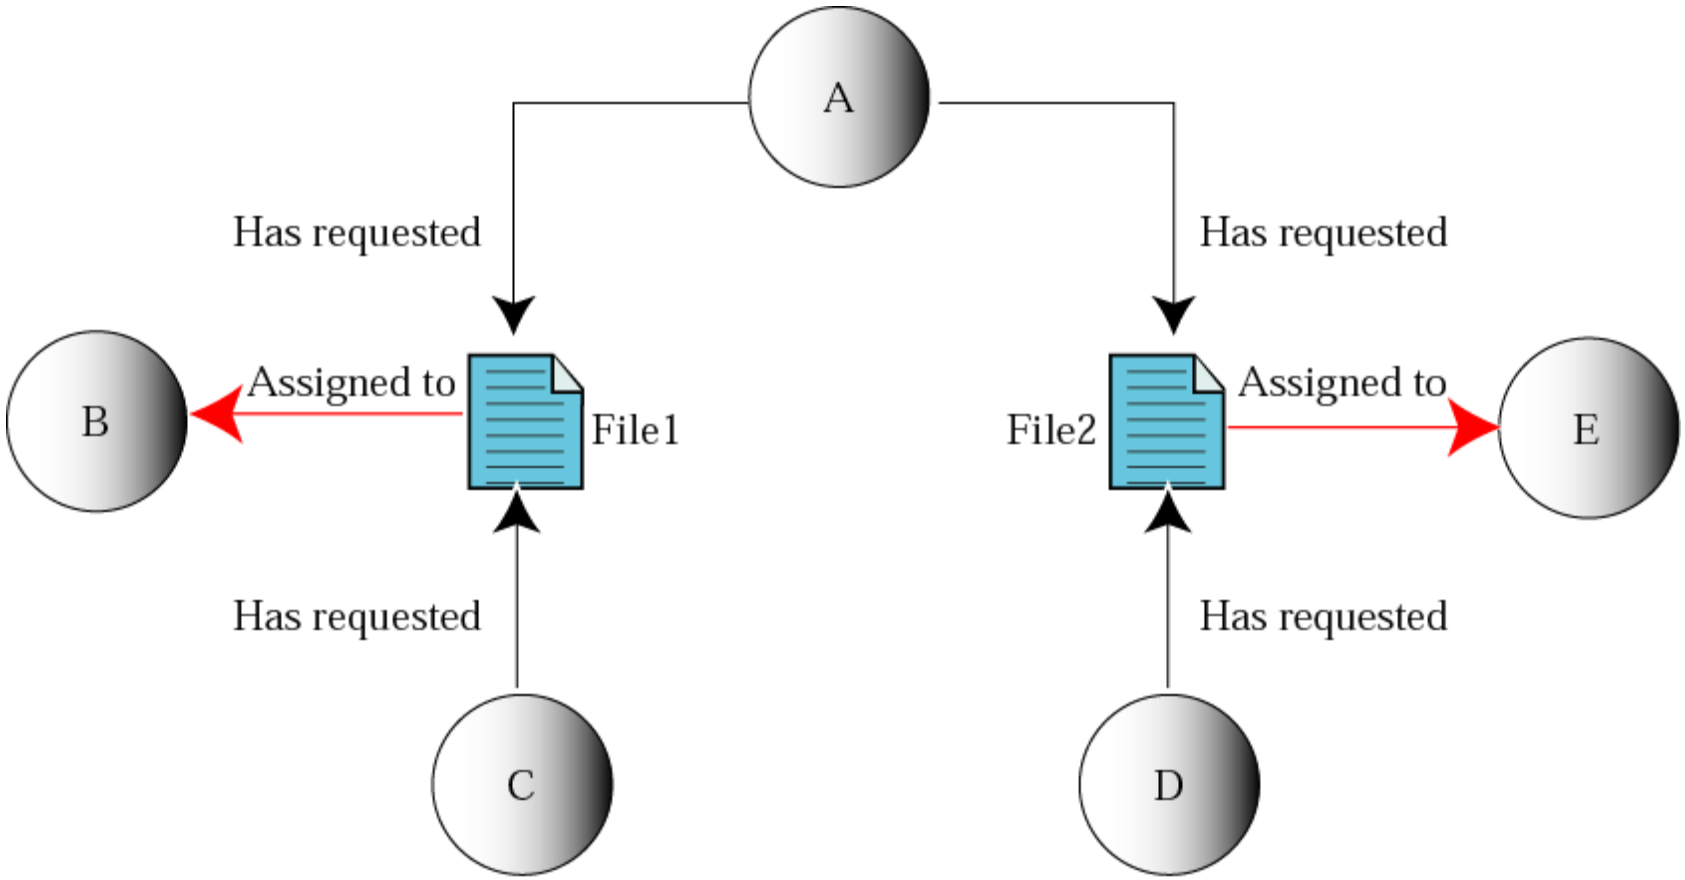

a. Process A needs both File1 and File2.

รูปที่ 7-15.b

Starvation

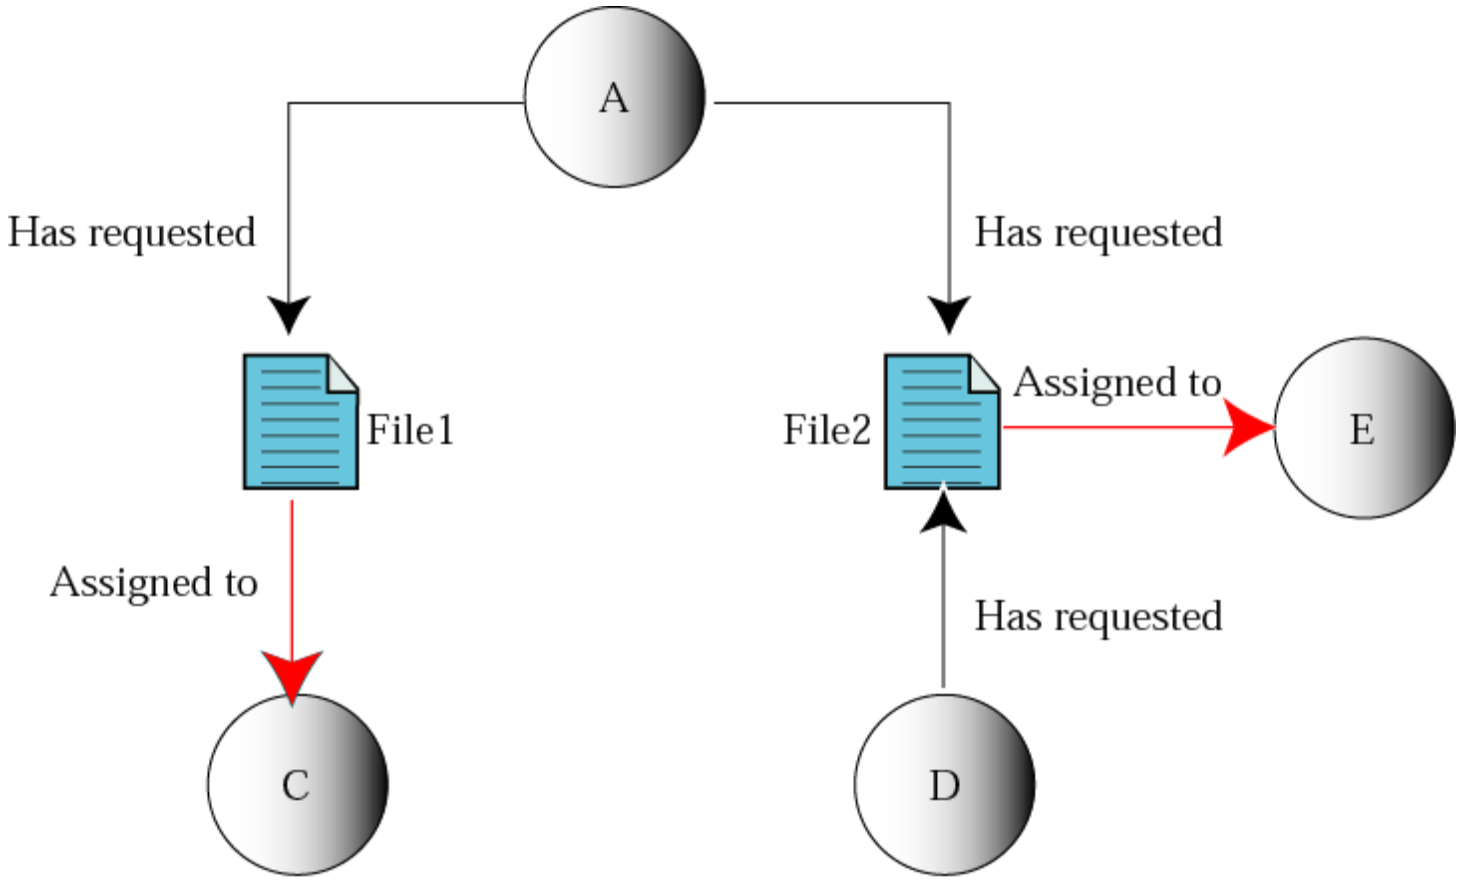

b. Process A still needs both File1 and File2.

รูปที่ 7-15.c

Starvation

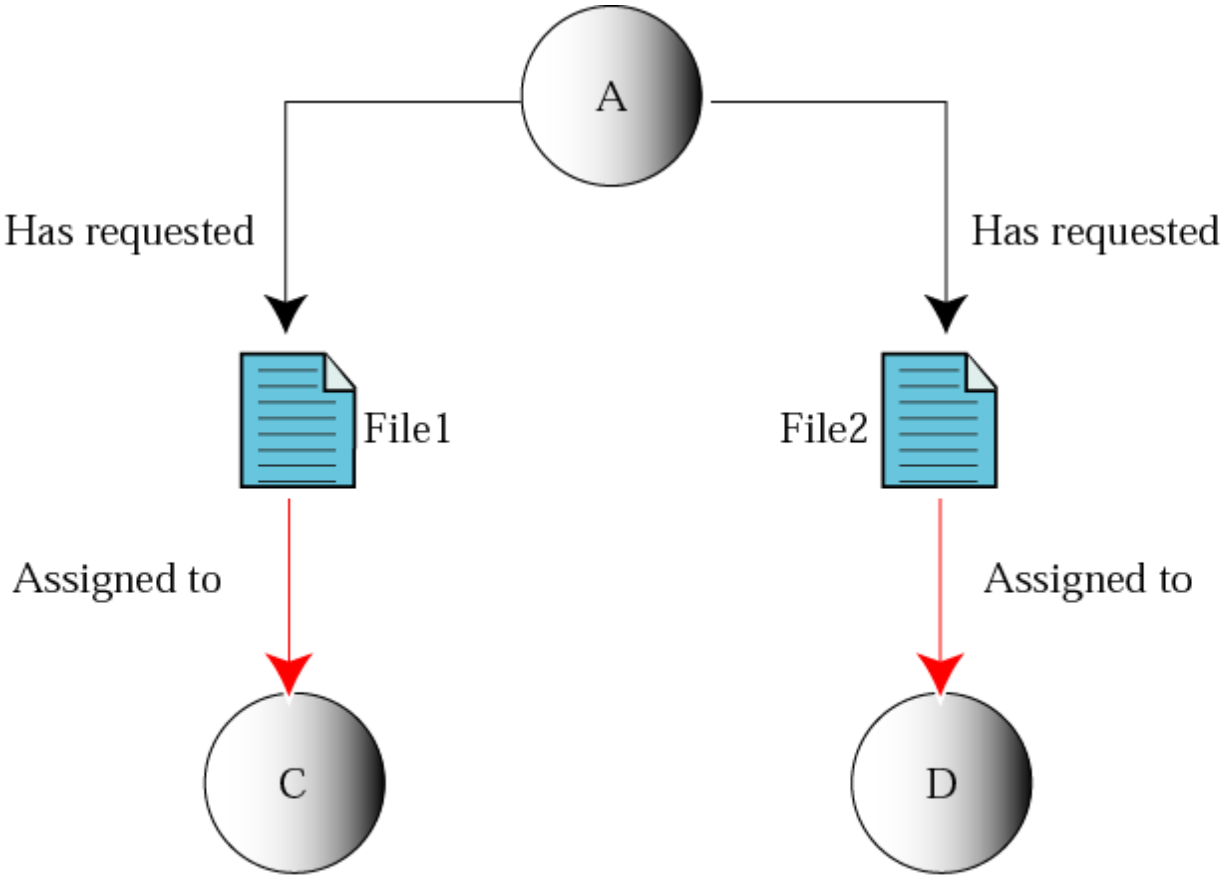

c. Process A still needs both File1 and File2 (starving).

ตัวอย่างของปัญหา starvation : ซึ่งเป็นที่รู้จักกันดีในวงการคอมพิวเตอร์คือ “Dining Philosophers” ซึ่งคิดค้นขึ้นโดยนักคอมพิวเตอร์ที่มีชื่อสียงมากคนหนึ่งคือ Dijkstra (ดังรูปที่ 7.16) ในรูปจะมีนักปรัชญา 5 คนนั่งรับประทานอาหารอยู่รอบโต๊ะกลม นักปรัชญาแต่ละคนต้องการช้อน 2 อันเพื่อที่จะทานข้าวในชาม สภาพการณ์เช่นนี้ คนที่นั่งติดกันซึ่งต้องการช้อนที่อยู่ระหว่างคนทั้งสองเหมือนกัน ถ้าคนหนึ่งใช้อยู่ อีกคนหนึ่งก็จะต้องรอจนกว่าคนที่ทานอยู่จะอิ่ม เมื่อปลดปล่อยช้อนออกมา อาหารคงหมดไปแล้ว!!!!!

รูปที่ 7-16

Dining philosophers

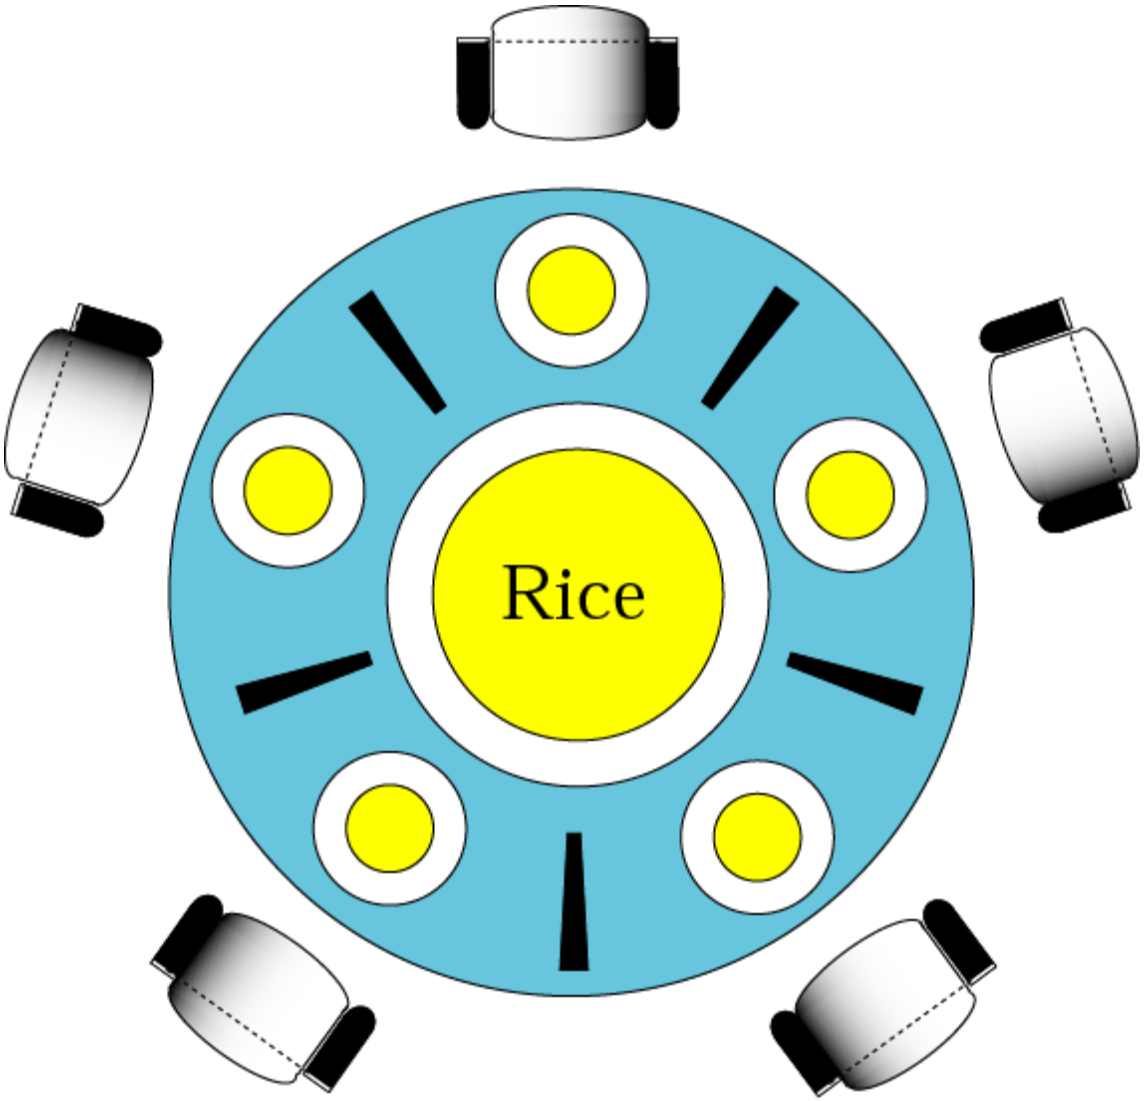

3. DEVICE MANAGEMENT

Device manager หรือ I/O manager ทำหน้าที่ควบคุมการใช้อุปกรณ์ I/O โดยปกติอุปกรณ์ I/O ในระบบคอมพิวเตอร์จะมีข้อจำกัดในเรื่องของจำนวนและความเร็วในการทำงาน เนื่องจากอุปกรณ์เหล่านี้ทำงานช้ามากเมื่อเทียบกับ CPU และหน่วยความจำหลัก เมื่อ process หนึ่งขอใช้อุปกรณ์ I/O ใดก็จะใช้เป็นระยะเวลาหนึ่ง (ที่ค่อนข้างยาวนานเมื่อเทียบกับความเร็วของ CPU) ซึ่งจะทำให้ process อื่นไม่สามารถใช้งานได้

Device manager มีหน้าที่ที่สำคัญสรุปได้ดังนี้

1. monitor อุปกรณ์ I/O ทุกชนิดให้สามารถทำงานได้อย่างปกติ
2. จัดสรรอุปกรณ์ I/O ให้กับ process ที่ร้องขอและปลดปล่อย
3. บริหารจัดการ queue ของอุปกรณ์แต่ละชนิด
4. กำหนดและควบคุมนโยบายในการใช้อุปกรณ์ I/O เช่น FIFO

4. FILE MANAGEMENT

ระบบปฏิบัติการทุกวันนี้ใช้ file manager ควบคุมการใช้แฟ้มข้อมูลของระบบ หน้าที่โดยรวมของ file manager สรุปได้ดังนี้

1) ควบคุมการใช้แฟ้มข้อมูลตามสิทธิที่แต่ process จะพึงมี เช่น process A สามารถอ่าน เขียน และ เปลี่ยนแปลงข้อมูลใน File1 ได้ แต่ process B สามารถอ่านได้เพียงอย่างเดียว

2) ควบคุมการสร้าง (creation) การลบ (deletion) และการแก้ไข (modification) แฟ้มข้อมูล

3) ควบคุมการตั้งชื่อและประเภทของแฟ้มข้อมูล

4) ควบคุมรูปแบบการจัดเก็บและตำแหน่งในการเก็บแฟ้มข้อมูลในหน่วยความจำหลักและหน่วยความจำสำรอง

5) รับผิดชอบการเก็บรักษา (archive) และการสำรองข้อมูล (backup)

7.4

ระบบปฏิบัติการที่นิยมใช้กันอย่างแพร่หลาย

ตัวอย่างระบบปฏิบัติการที่น่าสนใจ

ระบบปฏิบัติการมีการเปลี่ยนแปลงและพัฒนาอยู่ตลอดเวลา ระบบที่เป็นที่นิยมและรู้จักกันมากในวงการคอมพิวเตอร์มีอยู่หลายระบบ ที่ยกมาเพียงเป็นตัวอย่างเบื้องต้น

1) **WINDOWS 2000**: พัฒนาโดยบริษัทไมโครซอฟท์จำกัด มีประวัติการพัฒนาที่ยาวนาน เริ่มตั้งแต่การ interface โดย run ภายใต้ DOS ปัจจุบันเป็นระบบที่สลับซับซ้อน ใช้การ interface แบบ menu และ GUI ใช้เทคนิคหน่วยความจำเสมือนเพื่อสนับสนุน multiprogramming สนับสนุนการทำงานในระบบเครือข่ายโดยมีระบบรักษาความปลอดภัยของข้อมูลและการทำงานอันเป็นที่ยอมรับกันโดยทั่วไป

2) **UNIX**: เป็นระบบปฏิบัติการซึ่งเป็นที่นิยมใช้กันมากในหมู่นักเขียนโปรแกรมและนักคอมพิวเตอร์ เป็นระบบปฏิบัติการที่มีความ

สามารถสูง มีคุณสมบัติที่เด่น 3 ประการคือ

1) portable: คือสามารถเคลื่อน ย้ายจากคอมพิวเตอร์เครื่องหนึ่งไปใช้กับคอมพิวเตอร์อีกเครื่องหนึ่งได้โดย ง่าย ไม่ต้องมีการเปลี่ยนแปลงแก้ไขอะไรมาก ทั้งนี้เพราะว่า UNIX เขียนด้วยภาษา C

2) UNIX มีชุดของคำสั่งที่มีประสิทธิภาพจำนวนมาก ซึ่งคำสั่งเหล่านี้สามารถนำมารวมกัน (เรียกว่า script) เพื่อแก้ปัญหาได้สะดวกขึ้น

3) UNIX เป็นระบบที่เป็นไม่ขึ้นอยู่กับอุปกรณ์ เพราะ UNIX มีส่วนที่เรียกว่า device driver อยู่ในตัวของมันเองซึ่งสามารถกำหนดรูปแบบ (configure) อุปกรณ์ที่จะใช้ได้ กล่าวโดยสรุป UNIX เป็นระบบปฏิบัติการที่มีคุณลักษณะเด่นทุกประการที่ระบบปฏิบัติการจะพึงมี ซึ่งรวมถึง virtual memory, multiprogramming, file and directory systems จุดอ่อนอาจมีตรงที่เป็น command interface ใช้งานค่อนข้างยากสำหรับมือใหม่

3) LINUX: เป็นระบบปฏิบัติการที่พัฒนาโดย Linus Torvalds ชาวฟินแลนด์ โดยใช้ UNIX เป็นฐาน มีลักษณะใกล้เคียงกับ UNIX มาก บางคนถึงกับเรียกว่า UNIX clone แนวคิดทั้งหมดคือทำให้ประสิทธิภาพของ UNIX เพิ่มมากขึ้นเมื่อ run บน Intel microprocessor ปัจจุบัน LINUX เป็น open source OS ที่สามารถ run บน platform ต่างๆได้ เป็นที่นิยมใช้กันอย่างกว้างขวางในหมู่นักคอมพิวเตอร์และนักเขียนโปรแกรม
